



Praktikum

Analitik & Visualisasi Data

Final Project

SDGs (7) - Affordable & Clean Energy

Greindo_data.csv

Kelompok 01 – A1

2509116021	Ahmad Ahdasuki	Project Leader
2509116006	Muhammad Attar Khanza	Data Analyst
	Habibillah	
2509116013	Annisa Nayzhua Febriyani	Data Visualization



KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan kemudahan yang diberikan, sehingga laporan Final Project mata kuliah Praktikum Analitik & Visualisasi Data dengan studi kasus Greindo ini dapat diselesaikan dengan baik dan tepat waktu. Laporan ini merupakan bagian dari kegiatan Project Based Learning (PBL) pada Semester Genap 2025/2026 yang berfokus pada tema SDGs (7) — Affordable & Clean Energy.

Laporan ini disusun sebagai wujud tanggung jawab akademis sekaligus bentuk kontribusi nyata dalam menganalisis dan memvisualisasikan data operasional energi terbarukan di Indonesia. Melalui studi kasus ini, tim penulis berupaya mengidentifikasi pola pemanfaatan energi, mengevaluasi performa fasilitas, serta memberikan rekomendasi berbasis data yang dapat mendukung pengambilan keputusan strategis dalam transisi energi bersih nasional.

Dalam proses penyusunan laporan ini, penulis mendapatkan bimbingan, dukungan, dan bantuan dari berbagai pihak. Oleh karena itu, dengan segala kerendahan hati, penulis mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Dosen Pengampu Mata Kuliah Analitik & Visualisasi Data, yang telah memberikan arahan, materi perkuliahan, serta bimbingan selama proses pengerjaan proyek ini berlangsung.
2. Asisten Laboratorium (Aslab) dan Konsultan Praktikum, yang senantiasa memberikan pendampingan teknis, masukan dan saran, serta membantu menyelesaikan berbagai hambatan yang ditemui selama proses pengolahan dan analisis data.
3. Rekan-rekan satu tim, yang telah banyak membantu, berbagi ide, serta saling mendukung dalam setiap tahap pengerjaan proyek ini.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi penyempurnaan di masa mendatang. Semoga laporan ini dapat memberikan manfaat dan kontribusi yang berarti, tidak hanya bagi penulis,



tetapi juga bagi seluruh pihak yang membutuhkan referensi terkait analisis data energi terbaru di Indonesia.

Samarinda, April 2026

Kelompok 01



DAFTAR ISI

KATA PENGANTAR.....	1
DAFTAR ISI.....	3
DAFTAR GAMBAR.....	5
DAFTAR TABEL	7
BAB I PENDAHULUAN.....	9
1.1 Latar Belakang	9
1.2 Identifikasi Masalah	10
1.3 Tujuan Analisis	10
1.4 Manfaat Analisis	11
BAB II METODOLOGI.....	12
2.1 Data dan Sumber Data	12
2.2 Alur Pengerjaan Study Case.....	12
2.2.1 Tools yang digunakan dalam proses menganalisis data	12
2.2.2 Proses Analisis Data.....	13
2.2.2.1 Business Understanding	13
2.2.2.2 Data Understanding	14
2.2.2.3 Data Preparation	14
2.2.2.4 Construct Data	16
2.2.2.5 Data Reduction	16
BAB III HASIL DAN PEMBAHASAN	18
3.1 Deskripsi Data Hasil Analisis Bisnis	18
3.2 Hasil Analisis	19
3.2.1 Business Understanding	20
3.2.2 Data Understanding	25
3.2.3 Data Preparation	53
3.2.4 Construct Data	65
3.2.5 Data Reduction	65
3.2.6 Data Graph	66
3.2.7 Dashboard	75



3.3	Pembahasan	78
BAB IV KESIMPULAN DAN SARAN		81
4.1	Kesimpulan.....	81
4.2	Saran.....	81
Lampiran		82



DAFTAR GAMBAR

Gambar 1 Tampilan Dataset.....	26
Gambar 2 Informasi Dataset	27
Gambar 3 Deskriptif Statistik Dataset.....	29
Gambar 4 Tipe Data	31
Gambar 5 Data Kolom Wilayah.....	32
Gambar 6 Data Kolom Energi.....	32
Gambar 7 Missing Values	33
Gambar 8 Duplicated Values.....	34
Gambar 9 Outliers Values.....	36
Gambar 10 Perbandingan Kapasitas Antar Wilayah	38
Gambar 11 Perbandingan Produksi Energi Antar Wilayah	40
Gambar 12 Perbandingan Produksi Energi Berdasarkan Tipe Provider.....	42
Gambar 13 Proporsi Jenis Energi.....	44
Gambar 14 Proporsi Status Operasional.....	45
Gambar 15 Distribusi Kapasitas Terpasang	46
Gambar 16 Distribusi Produksi Energi	47
Gambar 17 Distribusi Populasi Terlayani.....	48
Gambar 18 Distribusi Jumlah Emisi Karbon	49
Gambar 19 Distribusi Laju Efisiensi.....	50
Gambar 20 Distribusi Skor Investasi.....	51
Gambar 21 Relasi Variabel Numerik	52
Gambar 22 Perbaikan Huruf Kapital Depan Kata	54
Gambar 23 Kolom Wilayah Setelah Ditangani.....	55
Gambar 24 Kolom Jenis Energi Setelah Ditangani.....	55
Gambar 25 Missing Values(Setelah Dibersihkan).....	61
Gambar 26 Duplicated Values(Setelah Dibersihkan).....	62
Gambar 27 Outliers Setelah Ditangani.....	64
Gambar 28 Tampilan Kolom.....	66
Gambar 29 Distribusi Terpasang Setiap Wilayah	67
Gambar 30 Proporsi Jenis Energi.....	68
Gambar 31 Tren Produksi Dari Waktu Ke Waktu.....	69
Gambar 32 Hubungan Antara Kapasitas Dan Produksi Energi Setiap Wilayah	70
Gambar 33 Proporsi Status Operasional.....	71
Gambar 34 Perbandingan Target Tercapai Berdasarkan Tipe Provider	72
Gambar 35 Biaya Operasional Antar Wilayah.....	73
Gambar 36 Persebaran Populasi Terlayani Antar Wilayah.....	74
Gambar 37 Dashboard Analisis Kinerja Energi Terbarukan Indonesia	76



Gambar 38 Dashboard Performa Operasional Dan Kinerja Energi Terbarukan 77



DAFTAR TABEL

Tabel 1.2 1 Identifikasi Data	10
Tabel 3. 1 Informasi Kolom Setelah Dibersihkan.....	18
Tabel 3.2.2 1 Kode Import Library	25
Tabel 3.2.2 2 Kode Memuat Dataset	26
Tabel 3.2.2 3 Kode Melihat Informasi Dataset.....	26
Tabel 3.2.2 4 Kode Melihat Deskriptif Statistik Dataset	29
Tabel 3.2.2 5 Kode Cek Tipe Data.....	31
Tabel 3.2.2 6 Cek Data Kolom Wilayah.....	32
Tabel 3.2.2 7 Kode Cek Kolom Jenis Energi	32
Tabel 3.2.2 8 Kode Cek Missing Values.....	33
Tabel 3.2.2 9 Kode Cek Duplicated Values	34
Tabel 3.2.2 10 Kode Cek Outliers.....	35
Tabel 3.2.2 11 Kode Bar Chart Perbandingan Kapasitas Antar Wilayah	37
Tabel 3.2.2 12 Kode Bar Chart Perbandingan Produksi Energi Antar Wilayah	39
Tabel 3.2.2 13 Kode Bar Chart Perbandingan Produksi Energi Berdasarkan Provider	41
Tabel 3.2.2 14 Kode Pie Chart Proporsi Jenis Energi	43
Tabel 3.2.2 15 Kode Pie Chart Proporsi Status Operasional.....	45
Tabel 3.2.2 16 Kode Distribusi Kapasitas Terpasang.....	46
Tabel 3.2.2 17 Kode Distribusi Produksi Energi.....	46
Tabel 3.2.2 18 Kode Distribusi Populasi Terlayani	47
Tabel 3.2.2 19 Kode Distribusi Emisi Karbon Terpangkas	48
Tabel 3.2.2 20 Kode Distribusi Laju Efisiensi	49
Tabel 3.2.2 21 Kode Skor Investasi	50
Tabel 3.2.2 22 Kode Relasi Setaip Variabel Numerik	51
Tabel 3.2.3. 1 Kode Ubah Tipe Data Menjadi Datetime	53
Tabel 3.2.3. 2 Kode Ubah Tipe Data Menjadi Int.....	53
Tabel 3.2.3. 3 Kode Menghapus Kata “IDR”	53
Tabel 3.2.3. 4 Kode Mengubah Variabel Ke Numerik	53
Tabel 3.2.3. 5 Kode Ubah Tipe Data Ke Float.....	54
Tabel 3.2.3. 6 Kode Membuat Huruf Besar Awal Kata	54
Tabel 3.2.3. 7 Kode Mapping Kolom Wilayah	54
Tabel 3.2.3. 8 Kode Mapping Kolom Jenis Energi	55
Tabel 3.2.3. 9 Kode Metode Modus Kolom Wilayah	56
Tabel 3.2.3. 10 Kode Metode Modus Kolom Target Tercapai.....	56



Tabel 3.2.3. 11 Kode Metode Median Kolom Populasi Terlayani.....	57
Tabel 3.2.3. 12 Kode Metode Median Kolom Emisi Karbon	58
Tabel 3.2.3. 13 Kode Metode Median Kolom Laju Efisiensi.....	58
Tabel 3.2.3. 14 Kode Metode Median Kolom Skor Investasi.....	59
Tabel 3.2.3. 15 Kode Mengisi “Unknown” Kolom Tipe Provider	59
Tabel 3.2.3. 16 Kode Metode Modus Kolom Status Operasional	60
Tabel 3.2.3. 17 Kode Mengisi “Unknown” Kolom Jenis Energi.....	60
Tabel 3.2.3. 18 Kode Cek Missing Values	61
Tabel 3.2.3. 19 Kode Menghapus Baris Duplikat	62
Tabel 3.2.3. 20 Kode Cek Duplicated Values.....	62
Tabel 3.2.3. 21 Kode Penanganan IQR Kolom Populasi Terlayani	62
Tabel 3.2.3. 22 Kode Cek Outlier Values.....	63
3.2.5. 1 Kode Hapus Kolom.....	65
3.2.5. 2 Kode Cek Kolom	66



BAB I

PENDAHULUAN

1.1 Latar Belakang

Transisi menuju energi bersih dan terjangkau merupakan salah satu pilar utama dalam pembangunan berkelanjutan di Indonesia, sebagaimana yang diamanatkan dalam Tujuan Pembangunan Berkelanjutan (SDGs) Nomor 7, yaitu memastikan akses terhadap energi yang terjangkau, andal, berkelanjutan, dan modern bagi semua pihak. Sektor energi terbarukan di Indonesia memiliki potensi yang sangat besar, mulai dari energi Solar, Air, Angin, dan Panas Bumi yang tersebar di berbagai wilayah kepulauan Nusantara.

Namun, tantangan utama yang dihadapi dalam pengembangan energi terbarukan bukan hanya terletak pada ketersediaan sumber daya alam semata, melainkan pada kemampuan pengelolaan data operasional yang efektif dan efisien. Kesenjangan informasi mengenai kapasitas pembangkit yang terpasang, efisiensi sistem, realisasi produksi energi, serta biaya operasional menjadi kendala serius dalam pengambilan keputusan strategis di tingkat regional maupun nasional. Ketidakakuratan atau ketidaklengkapan data dapat menyebabkan misalokasi sumber daya, ketidaktepatan proyeksi, dan hambatan dalam pencapaian target energi nasional.

Greindo, sebagai perusahaan startup teknologi analitik yang didirikan pada tahun 2024, hadir untuk menjembatani kesenjangan tersebut. Greindo berfokus pada pengumpulan, pengolahan, dan analisis performa infrastruktur energi terbarukan guna mendukung transisi energi nasional yang berkelanjutan. Dengan mengintegrasikan berbagai metrik kunci ke dalam satu platform terpadu, Greindo memungkinkan pemangku kepentingan untuk mengakses informasi yang akurat dan komprehensif.

Dataset yang digunakan dalam proyek ini adalah `Greindo_data.csv`, yang memuat data operasional energi bersih dari berbagai wilayah di Indonesia. Data ini mencakup variabel-variabel seperti kapasitas terpasang (MW), realisasi produksi energi (GWh), laju efisiensi, biaya operasional, emisi karbon terpangkas, populasi terlayani, tipe provider, status operasional fasilitas, serta skor investasi. Dataset ini awalnya dalam kondisi yang sangat kotor dan tidak terstandarisasi,



dengan berbagai permasalahan mulai dari nilai yang tidak konsisten, nilai kosong data duplikat, hingga nilai-nilai ekstrem yang dapat mendistorsi hasil analisis.

1.2 Identifikasi Masalah

Berdasarkan pembahasan latar belakang di atas, permasalahan yang dapat diidentifikasi dalam proyek ini dapat dijabarkan sebagai berikut. Tabel 1.2.1 menyajikan ringkasan identifikasi masalah beserta deskripsinya.

Tabel 1.2 1 Identifikasi Data

Masalah	Deskripsi
Kualitas Data masih belum bagus	Dataset Greindo mengandung nilai inkonsisten, missing values, data duplikat, dan outliers yang dapat mendistorsi hasil analisis.
Ketimpangan Distribusi Kapasitas	Terdapat ketidakmerataan distribusi kapasitas terpasang (MW) antar wilayah yang menghambat pemerataan akses energi.
Inefisiensi Operasional	Banyak fasilitas yang tidak beroperasi secara optimal, terbukti dari 60% fasilitas berstatus maintenance atau rusak.
Ketidaksesuaian Kapasitas dan Produksi Energi	Terdapat indikasi lokasi dengan kapasitas terpasang tinggi namun realisasi produksi energi masih rendah.
Belum Diketahui Target Pencapaian Apakah Sudah Optimal	Belum di ketahui target pencapaian berdasarkan tipe provider apakah dominan pada “Yes” atau “No” agar dapat menjadi bahan evaluasi.
Kesenjangan Biaya Operasional	Biaya operasional per unit energi yang dihasilkan bervariasi signifikan antar wilayah, menunjukkan adanya inefisiensi pada wilayah tertentu.

1.3 Tujuan Analisis

Berdasarkan identifikasi masalah di atas, tujuan dari analisis proyek ini adalah:

1. Membersihkan dan mempersiapkan dataset Greindo sehingga siap digunakan untuk analisis yang akurat dan komprehensif.



2. Mengidentifikasi pola distribusi kapasitas terpasang dan realisasi produksi energi di berbagai wilayah Indonesia.
3. Mengevaluasi performa operasional fasilitas energi berdasarkan status operasional, tipe provider, dan tingkat pencapaian target.
4. Menganalisis efisiensi biaya operasional dan kontribusi setiap jenis energi terbarukan terhadap total produksi nasional.
5. Menyajikan hasil analisis dalam bentuk visualisasi dan dashboard interaktif di Tableau sebagai dasar pengambilan keputusan strategis.

1.4 Manfaat Analisis

Hasil dari analisis ini diharapkan dapat memberikan manfaat yang signifikan bagi berbagai pihak seperti Pemerintah, Perusahaan Asing dan Perusahaan Swasta. Dengan hasil analisis ini juga dapat dimanfaatkan sebagai dasar dalam merumuskan kebijakan energi yang lebih tepat sasaran, terukur, dan berbasis data. Bagi pengelola fasilitas energi, analisis ini berperan dalam membantu mengidentifikasi area yang memerlukan peningkatan efisiensi operasional, sekaligus mengevaluasi kinerja fasilitas secara menyeluruh. Sementara itu, bagi akademisi dan peneliti, hasil analisis ini dapat dijadikan sebagai referensi dalam pengembangan metodologi analisis data, khususnya di bidang energi terbarukan. Dengan demikian, analisis ini tidak hanya menghasilkan insight yang bermanfaat secara praktis, tetapi juga memberikan kontribusi dalam pengembangan ilmu pengetahuan serta mendukung pengambilan keputusan yang lebih strategis dan berkelanjutan.



BAB II METODOLOGI

2.1 Data dan Sumber Data

Data yang digunakan dalam proyek ini berasal dari dataset perusahaan Greindo, yaitu file `Greindo_data.csv`. Dataset ini memuat data operasional energi bersih dan terbarukan dari berbagai wilayah di Indonesia dalam rentang waktu dari tahun 2021 sampai dengan 2024. Jenis data yang digunakan merupakan kombinasi antara data numerik, seperti kapasitas terpasang, produksi energi, biaya operasional, dan populasi terlayani, lalu ada juga data kategorikal, seperti jenis energi, tipe provider, status operasional, dan status pencapaian target.

Dataset ini terdiri dari 5.150 baris data dan 14 kolom atribut. Sebelum dilakukan analisis, dataset harus melewati berbagai proses pembersihan terlebih dahulu untuk mengatasi permasalahan kualitas data yang ditemukan, sehingga data yang digunakan dalam analisis akhir merupakan data yang telah bersih dan terstandarisasi.

2.2 Alur Pengerjaan Study Case

Alur proses pengerjaan studi kasus pada dataset Greindo ini melewati berbagai tahapan seperti yang telah disesuaikan dengan kebutuhan proyek dan tahapan nya itu mencakup seperti, Business Understanding, Data Understanding, Data Preparation, dan Data Visualization. Alur pengerjaan secara sistematis dimulai dari pemahaman konteks bisnis, eksplorasi data, pembersihan data, hingga visualisasi dan pembuatan dashboard.

2.2.1 Tools yang digunakan dalam proses menganalisis data

Dalam proses analisis dan visualisasi data, beberapa perangkat lunak digunakan secara terintegrasi. Pertama, *Python* digunakan sebagai bahasa pemrograman utama untuk proses pengolahan dan analisis data. *Python* dipilih karena kemampuannya yang sangat fleksibel, lalu didukung juga oleh ekosistem *library* yang kaya, serta dapat menangani berbagai operasi data dari yang sederhana hingga kompleks. *Library* utama yang digunakan mencakup *Pandas* untuk manipulasi data dalam bentuk tabel, *Seaborn* untuk mendukung



operasi numerik, *Matplotlib.pyplot* untuk membuat dan mengatur berbagai jenis visualisasi seperti grafik garis, histogram, bar chart dan lain-lain., *Numpy* untuk menandai atau mendeteksi nilai kosong tersebut (sebagai np.nan) sebelum di proses lebih lanjut, *Warnings* untuk mengatur pesan peringatan(bukan pesan eror), dan terakhir ada *Sns.set(style='whitegrid')* untuk mengatur semua grafik yang akan dibuat, jika *matplotlib* adalah pondasi maka baris ini menentukan ke estetika nya. Proses pengolahan ini dilakukan melalui *Google Colaboratory* yang memudahkan kolaborasi tim secara *real-time*.

Lalu Selanjutnya ada *tools Tableau* yang digunakan sebagai platform utama untuk pembuatan visualisasi final dan dashboard interaktif. *Tableau* dipilih karena kemampuannya menghasilkan visualisasi yang profesional, interaktif, dan mudah dipahami oleh berbagai kalangan pemangku kepentingan tanpa memerlukan kemampuan pemrograman yang mendalam. Dengan fitur *drag-and-drop* dan berbagai jenis chart yang tersedia, *Tableau* memungkinkan penyajian insight yang kompleks secara visual yang intuitif.

2.2.2 Proses Analisis Data

Pada bagian ini dijelaskan tahapan-tahapan yang dilakukan dalam proses analisis data pada dataset Greindo. Proses ini dilakukan secara bertahap agar data yang digunakan benar-benar siap untuk dianalisis dan menghasilkan insight yang bagus. Dimulai dari memahami konteks bisnis yang ingin dicapai, kemudian mengenali karakteristik data, hingga melakukan pembersihan dan penyesuaian data agar lebih rapi dan konsisten.

2.2.2.1 Business Understanding

Pada tahap ini dilakukan pemahaman mendalam terhadap konteks bisnis Greindo sebagai perusahaan startup teknologi analitik. Pemahaman mencakup identifikasi tujuan bisnis *Business Objective*, penilaian situasi saat ini *Assess Situation*, penetapan tujuan analitik *Analytic Goals*, serta



penyusunan rencana untuk kedepan nya *Project Plan*. Tujuan utama bisnisnya ialah membantu pemerintah memahami kondisi energi terbarukan melalui analisis data yang komprehensif, serta memberikan insight untuk meningkatkan efisiensi operasional fasilitas dan mendorong pemerataan akses energi bersih.

2.2.2.2 Data Understanding

Pada tahap ini saya masuk pada proses eksplorasi terhadap dataset dari “Greindo” agar lebih memahami karakteristik dataset tersebut, dengan beberapa langkah, sebagai berikut:

- Mengecek jumlah baris dan kolom.
- Pemeriksaan statistik deskriptif dataset.
- Mengidentifikasi tipe data setiap kolom.
- Membuat visualisasi Bar Chart untuk kapasitas dan produksi antar wilayah atau provider.
- Membuat visualisasi Pie Chart untuk melihat proporsi jenis energi dan status operasional.
- Membuat visualisasi Line Chart untuk melihat tren produksi energi dari waktu ke waktu.
- Membuat visualisasi Histogram untuk melihat distribusi setiap variabel numerik.
- Membuat visualisasi Box Plot untuk mendeteksi outliers pada setiap kolom.
- Membuat visualisasi Heatmap untuk melihat korelasi antar variabel numerik

2.2.2.3 Data Preparation

Pada tahap ini dilakukan proses persiapan data agar dataset menjadi lebih bersih, konsisten, dan siap untuk dianalisis. Mengingat masih terdapat



beberapa permasalahan seperti ketidakkonsistenan nilai, data hilang, duplikasi, dan outlier, maka diperlukan penanganan yang tepat sesuai dengan karakteristik data. Proses ini bertujuan untuk meningkatkan kualitas data sehingga hasil analisis menjadi lebih akurat dan dapat dipercaya.

a) Inconsistent Values

Penanganan dilakukan dengan metode title case yaitu mengubah huruf awal menjadi kapital untuk normalisasi penulisan, serta menggunakan mapping/replace untuk mengganti nilai yang tidak konsisten seperti 'Sumtra' menjadi 'Sumatera', 'Java' menjadi 'Jawa', 'Hydro Power' menjadi 'Hydro', dan 'S_Energy' menjadi 'Solar'. Selain itu, dilakukan perbaikan tipe data pada kolom tanggal_laporan menjadi datetime, tahun menjadi integer, dan biaya_operasional menjadi float. Pendekatan ini dipilih karena paling efektif dalam menstandarisasi nilai kategorikal tanpa kehilangan data.

b) Missing Values

Penanganan bervariasi sesuai karakteristik kolom. Kolom numerik seperti populasi_terlayani, emisi_karbon_terpangkas, laju_efisiensi, dan skor_investasi diisi menggunakan nilai median, karena median ditentukan berdasarkan nilai tengah dari data yang sudah diurutkan, sehingga tidak dipengaruhi oleh seberapa besar atau kecil nilai ekstrem yang ada. Sebaliknya, mean dihitung dari jumlah seluruh nilai lalu dibagi dengan banyaknya data, sehingga satu nilai yang sangat tinggi atau sangat rendah dapat mengubah hasil rata-rata secara signifikan, itulah sebabnya metode median lebih tahan terhadap nilai outlier. Pada kolom kategorikal seperti wilayah, status_operasional, dan target_tercapai diisi menggunakan nilai modus yaitu nilai yang paling sering muncul, karena modus memang khusus juga untuk kolom kategorikal sedangkan median dan mean untuk kolom numerik dan juga metode modus ini merepresentasikan kategori yang paling sering muncul dalam data, sehingga dianggap sebagai nilai yang paling umum



dan paling mendekati kondisi sebenarnya. Sedangkan kolom `tipe_provider` dan `jenis_energi` diisi dengan label 'Unknown' untuk menghindari bias berlebihan akibat proporsi missing value yang cukup besar sekitar 20% pada `jenis_energi` dan sekitar 34% pada `tipe_provider`.

c) Duplicated Values

Penghapusan data duplikat dilakukan menggunakan fungsi `drop_duplicates()` dari *library Pandas*. Metode ini dipilih karena paling efisien dan langsung untuk menghilangkan baris-baris yang identik secara keseluruhan, sehingga setiap observasi menjadi unik dan perhitungan tidak terdistorsi akibat pencatatan ganda.

d) Outliers Values

Pendeteksian outlier menggunakan metode *Interquartile Range*. Dari hasil deteksi, hanya kolom `populasi_terlayani` yang ditangani menggunakan metode *clipping* yaitu pembatasan nilai pada batas IQR, karena ditemukan nilai negatif yang tidak logis secara konteks. Outlier pada kolom `kapasitas_terpasang_mw` dan `laju_efisiensi` dibiarkan karena masih dapat dijelaskan secara kontekstual dalam domain energi.

2.2.2.4 Construct Data

Pada tahap ini tidak dilakukan penambahan atau pembentukan variabel baru dalam dataset, karena seluruh kolom yang tersedia sudah cukup representatif dan mendukung kebutuhan proses analisis. Struktur data yang ada sudah mampu menggambarkan informasi yang dibutuhkan secara jelas dan komprehensif.

2.2.2.5 Data Reduction

Reduksi data dilakukan dengan menghapus kolom `tahun` dari dataset menggunakan perintah `df.drop('tahun', axis=1)`. Kolom ini dihapus karena informasi `tahun` sudah tercakup dalam kolom `tanggal_laporan`, sehingga keberadaannya bersifat berulang. Penghapusan kolom ini bertujuan untuk



membuat struktur dataset menjadi lebih ringkas dan meningkatkan efisiensi proses pengolahan data selanjutnya.



BAB III

HASIL DAN PEMBAHASAN

3.1 Deskripsi Data Hasil Analisis Bisnis

Pada bagian ini dijelaskan gambaran umum terkait data setelah melewati proses pengolahan dan analisis. Data yang digunakan merupakan hasil dari tahap pembersihan, sehingga kualitasnya menjadi lebih baik dibandingkan kondisi awal. Tujuan dari penjelasan ini adalah untuk memberikan pemahaman mengenai struktur data yang digunakan, serta memastikan bahwa data tersebut telah siap digunakan dalam proses analisis agar dapat menghasilkan insight yang akurat dan dapat dipercaya.

a) Jumlah Data, Jumlah Baris, Jumlah Kolom (sesudah dibersihkan)

Setelah melalui proses pembersihan data yang komprehensif mencakup penanganan inconsistent values, missing values, duplicated values, dan outliers, serta pengurangan kolom yang redundan, hasil analisis akhirnya ialaha sekarang dataset meiliki 5105 baris dan memiliki 13 kolom. Seluruh kolom telah dipastikan memiliki tipe data yang sesuai dan tidak ada lagi nilai kosong , sehingga data siap digunakan untuk analisis lebih lanjut.

b) Informasi Kolom dalam Dataset

Tabel 3. 1 Informasi Kolom Setelah Dibersihkan

Kolom	Tipe Data	Deskripsi	Masalah
Tanggal_laporan	Datetime	Tanggal pencatatan data	Tipe data awal object.
wilayah	Object	Nama wilayah atau pulau di Indonesia	Inkonsistensi penulisan (Java seharusnya Jawa, Sumtra seharusnya Sumatera), missing sekitar 5%



Jenis_energi	Object	Sumber energi terbarukan yang digunakan	Inkonsistensi (S_Energy seharusnya Solar, Hydro Power seharusnya Hydro); Missing sekitar 20%
Tipe_provider	Object	Pengelola fasilitas energi	Missing sekitar 34%
Status_operasional	Object	Kondisi fasilitas; Aktif, Maintenance, Broken	Missing sekitar 10%
Kapasitas_terpasang_mw	Float64	Total kapasitas pembangkit(mw)	Outlier sebesar 0.39%
Produksi_energi_gwh	Float64	Total produksi energi (gwh)	Tidak ada outlier dan distribusi stabil
Populasi_terlayani	Float64	Jumlah penduduk yang mendapat akses (juta)	Missing sekitar 17%
Biaya_operasional	Float64	Biaya operasional dan perawatan fasilitas	Tipe data awal object
Emisi_karbon_terpangkas	Float64	Estimasi CO2 yang berhasil di cegah (ton)	Missing sekitar 11%
Laju_efisiensi	Float64	Presentase kinerja pembangkit	Missing sekitar 11%
Skor_investasi	Float64	Penilaian proyek dengan skala (1-10)	Missing sekitar 12%
Target_tercapai	Object	Status pencapaian target produksi (Yes/No)	Missing sekitar 1%

3.2 Hasil Analisis

Pada bagian ini dijelaskan hasil analisis yang diperoleh dari tahapan pengolahan data yang telah dilakukan sebelumnya. Hasil tersebut disusun untuk menjawab permasalahan bisnis yang



telah diidentifikasi, sekaligus memberikan gambaran yang lebih jelas mengenai kondisi dan kinerja energi terbarukan.

3.2.1 Business Understanding

a. Business Objective

Greindo merupakan perusahaan startup yang berfokus pada analisis data energi bersih di Indonesia. Dalam implementasinya, sektor energi terbarukan masih menghadapi beberapa permasalahan, seperti ketimpangan pemanfaatan energi antar wilayah, ketidaksesuaian antara kapasitas terpasang dengan produksi energi, serta tingginya biaya operasional yang belum sebanding dengan output yang dihasilkan.

Tujuan utama analisis proyek ini ialah untuk mengidentifikasi pola pemanfaatan energi terbarukan di berbagai wilayah Indonesia, mengevaluasi performa operasional fasilitas, serta memahami faktor-faktor finansial dan teknis yang mempengaruhi ketercapaian target energi nasional. Melalui dataset yang ada ini mencakup kapasitas terpasang, produksi energi, efisiensi, biaya operasional, hingga emisi karbon, perusahaan berupaya meningkatkan efisiensi operasional fasilitas energi, memastikan pencapaian target produksi, serta mendorong pemerataan akses energi bersih bagi masyarakat. Selain itu, Greindo juga bertujuan memberikan insight yang relevan bagi pemerintah dalam menilai kelayakan proyek energi melalui indikator seperti skor investasi dan performa operasional, sehingga dapat mempercepat transisi menuju energi yang berkelanjutan dan ramah lingkungan.

b. Asses Situation

Saat ini kondisi data Greindo masih menghadapi beberapa permasalahan mendasar yang memengaruhi kualitas analisis, yaitu data yang tersebar, tidak terstandarisasi, serta memiliki banyak nilai kosong atau null, sehingga sulit diintegrasikan menjadi informasi yang utuh dan komprehensif. Kondisi ini menyebabkan keterbatasan dalam memahami hubungan penting, seperti antara



kapasitas terpasang dengan realisasi produksi energi, serta menyulitkan dalam menilai tingkat efisiensi dan kinerja fasilitas secara akurat. Selain itu, terdapat ketimpangan performa antar wilayah dan jenis energi, yang menunjukkan bahwa pemanfaatan energi terbarukan belum merata, ditambah dengan variasi status operasional fasilitas seperti aktif, maintenance, dan rusak yang mengindikasikan bahwa tidak semua fasilitas beroperasi secara optimal.

Dampaknya, pencapaian target produksi energi menjadi tidak konsisten di berbagai wilayah. Meskipun demikian, dataset ini memiliki potensi besar untuk dimanfaatkan dalam mengidentifikasi sumber energi yang paling efisien, mengoptimalkan biaya operasional, serta meningkatkan kontribusi terhadap pengurangan emisi karbon, sehingga diperlukan pengolahan dan analisis data yang tepat untuk menghasilkan insight yang akurat dan mendukung pengambilan keputusan strategis dalam pengembangan energi berkelanjutan.

c. Analytic Goals

Analytic goals adalah tujuan analisis yang menjelaskan apa yang ingin dicapai dari pengolahan data secara spesifik dan terarah. Analytic goals berfungsi sebagai panduan dalam menentukan pertanyaan analisis, metode yang digunakan, serta jenis visualisasi yang relevan, sehingga proses analisis tidak bersifat acak. Kali ini analisis akan dilakukan pada dataset Greindo, dengan tujuan analisis ini adalah untuk memahami pemanfaatan energi terbarukan di Indonesia dengan mengidentifikasi pola distribusi antar wilayah, mengevaluasi performa operasional fasilitas berdasarkan kapasitas dan produksi energi, serta menganalisis faktor finansial dan teknis seperti biaya operasional dan efisiensi. Hasil analisis ini diharapkan dapat memberikan insight untuk meningkatkan efisiensi, pemerataan energi, dan mendukung pencapaian target energi nasional.

1. Menganalisis tren produksi energi dari waktu ke waktu dengan menggunakan Visualisasi Line Chart.



Line chart digunakan untuk melihat perubahan produksi_energi_GWh berdasarkan waktu tanggal_laporan atau tahun, sehingga dapat membantu mengidentifikasi pola kenaikan atau penurunan produksi serta kemungkinan adanya fluktuasi musiman.

2. Mengidentifikasi jenis energi dengan kontribusi terbesar dengan menggunakan Visualisasi Pie Chart.

Pie chart digunakan untuk menunjukkan persentase kontribusi masing-masing jenis_energi terhadap total produksi energi, agar dapat mengetahui energi mana yang paling dominan dalam mendukung produksi energi.

3. Menilai ketimpangan distribusi kapasitas dan produksi antar wilayah dengan menggunakan Visualisasi Bar Chart

Bar chart digunakan untuk membandingkan kapasitas_terpasang_mw dan produksi_energi_gwh antar wilayah untuk mengetahui apakah terdapat wilayah dengan kapasitas besar namun produksi rendah, atau sebaliknya.

4. Mengetahui presentase status operasional fasilitas energi dengan menggunakan Visualisasi Pie Chart

Pie Chart digunakan untuk melihat jumlah presentase fasilitas berdasarkan status_oprasional Aktif, Maintenance, Rusak, demi membantu memahami kondisi operasional dan kesiapan infrastruktur energi.

5. Menganalisis efisiensi biaya operasional terhadap energi yang dihasilkan pada suatu wilayah dengan menggunakan Visualisasi Bar Chart

Bar chart digunakan untuk menunjukkan perbandingan biaya operasional terhadap produksi energi pada suatu wilayah. Untuk membantu mengidentifikasi wilayah mana yang memiliki biaya paling murah dan paling efisien.

6. Menganalisis performa provider dalam pencapaian target energi dengan menggunakan Visualisasi Bar Chart



Bar chart digunakan untuk membandingkan jumlah proyek dengan status target_tercapai berdasarkan tipe_provider untuk menjadi bahan evaluasi efektivitas pada masing masing provider.

7. Menganalisis hubungan antara kapasitas dan produksi energi dengan menggunakan Visualisasi Scatter Plot

Scatter plot digunakan untuk melihat hubungan antara kapasitas_terpasang_mw dan produksi_energi_gwh, untuk membantu mengidentifikasi korelasi serta mendeteksi anomali atau inefisiensi pada data tersebut

8. Melihat pemerataan akses energi berdasarkan wilayah dengan menggunakan Visualisasi Tree Map

Map digunakan untuk menampilkan distribusi populasi_terlayani di setiap wilayah. Gunanya untuk membantu mengidentifikasi wilayah dengan akses energi tinggi maupun rendah serta melihat ketimpangan distribusi energi secara geografis.

d. Project Plan

Project plan adalah rencana terstruktur yang menjelaskan tahapan, langkah kerja, dan strategi yang akan dilakukan untuk menyelesaikan suatu proyek dari awal hingga akhir. Project plan berfungsi sebagai panduan agar proses pengerjaan berjalan sistematis, terarah, dan sesuai tujuan yang telah ditetapkan. Dan kali ini kita akan melakukan project plan akan di lakukan pada dataset Greindo untuk mengatasi,memperbaiki dan membersihkan dataset Greindo agar menghasilkan visualisasi yang bagus.

1. Business Understanding

Memahami tujuan Greindo sebagai startup yang berfokus pada analisis data energi bersih untuk mendukung pengambilan keputusan strategis dalam pengembangan energi terbarukan di Indonesia. Pada tahap ini juga diidentifikasi permasalahan utama seperti ketimpangan distribusi energi antar wilayah, ketidakefisienan antara kapasitas dan produksi, serta belum optimalnya pencapaian target produksi. Selain



itu, terdapat kebutuhan untuk meningkatkan efisiensi operasional, menekan biaya, serta mendukung pengurangan emisi karbon dan pemerataan akses energi.

2. Data Understanding

Mengenal struktur dataset yang mencakup variabel seperti tanggal laporan, wilayah, jenis energi, kapasitas terpasang, produksi energi, biaya operasional, efisiensi, emisi karbon, dan skor investasi. Tujuannya untuk memahami pola awal dataset, tipe data, distribusi nilai, serta hubungan awal antar variabel.

Pada tahap ini juga ada di lakukan namanya EDA (Exploratory Data Analysis) untuk mengetahui informasi penting dari data melalui sebuah visualisasi, yaitu:

- Barchart digunakan untuk membandingkan kapasitas, produksi, dan performa antar wilayah atau provider.
- Pie Chart digunakan untuk melihat proporsi kontribusi masing-masing jenis energi.
- Line Chart di gunakan untuk melihat tren produksi energi dari tahun ke tahun
- Histogram digunakan untuk melihat distribusi kolom dengan variabel numerik.
- Box Plot untuk mendeteksi outlier atau nilai ekstrem yang terlalu tinggi ataupun terlalu rendah pada setiap variabel numerik.
- Heatmap untuk melihat hubungan setiap kolom numerik.

3. Data Preparation

Membersihkan dataset dari segala permasalahan seperti data yang terduplikat, missing values atau ada nilai yang kosong, outlier pada variabel numerik, inconsisten struktur yang ada pada dataset. Semua permasalahan di atas harus kita bersihkan agar analisis dan visualisasi kedepannya mudah untuk di pahami. Selanjutnya setelah tahap cleaning, lanjut ke tahap construct data yaitu menambahkan kolom baru untuk lebih mendalami dalam proses analisis dan data reduction untuk menghapus kolom yang tidak relevan dalam analisis data Greindo ini.

4. Visualisasi dan Dashboard

Membuat visualisasi menggunakan Tableau berupa Bar Chart, Pie Chart, Line Chart, Histogram, Scatter Plot dan Map agar hasil analisis lebih mudah di pahami



oleh stakeholder dan dapat menjawab semua persoalan bisnis pada analisis tersebut. Seluruh proses analisis dan temuan didokumentasikan secara sistematis, kemudian disajikan dalam bentuk dashboard interaktif yang informatif dan terstruktur.

5. Insight and Recommendation

Menyimpulkan semua insight yang didapat dari hasil analisis dan memberikan saran ataupun rekomendasi terkait jika nanti ada kendala, perbaikan ataupun evaluasi demi menjaga kelancaran proses pengelolaan persebaran data energi terbarukan ini pada setiap wilayah di Indonesia. Adapun beberapa saran yang bisa diberikan yaitu pemerataan distribusi energi antar wilayah, peningkatan efisiensi operasional fasilitas, prioritas investasi pada energi dan wilayah yang potensial, dan strategi pengurangan emisi karbon secara lebih efektif.

3.2.2 Data Understanding

Tabel 3.2.2 1 Kode Import Library

<pre>1. import pandas as pd 2. import seaborn as sns 3. import matplotlib.pyplot as plt 4. import numpy as np 5. from sklearn.impute import KNNImputer 6. import warnings 7. warnings.filterwarnings('ignore') 8. sns.set(style='whitegrid')</pre>
--

Kode di atas digunakan untuk mempersiapkan lingkungan analisis data dan visualisasi. *Library pandas* digunakan untuk mengelola serta memanipulasi data dalam bentuk tabel. *Seaborn* digunakan untuk membantu pembuatan visualisasi data yang lebih menarik, sedangkan *matplotlib.pyplot* berperan sebagai dasar dalam membuat berbagai jenis grafik seperti line chart, histogram, dan bar chart. Selain itu, *NumPy* digunakan untuk operasi numerik serta untuk



merepresentasikan nilai kosong dalam bentuk *np.nan*. Proses penanganan data hilang dibantu dengan *KNNImputer* dari *library sklearn*, yang berfungsi mengisi nilai yang kosong dengan cara memperkirakan berdasarkan data terdekat. *Library warnings* digunakan untuk mengatur pesan peringatan, dan fungsi *warnings.filterwarnings('ignore')* digunakan untuk menyembunyikan pesan peringatan agar tidak mengganggu proses analisis. Terakhir, *sns.set(style='whitegrid')* digunakan untuk mengatur tampilan visualisasi agar lebih rapi dan mudah dibaca dengan latar grid yang bersih.

1. Memuat Dataset

Tabel 3.2.2 2 Kode Memuat Dataset

2. file = '/content/drive/MyDrive/PA AVD PA/Greindo_data.csv'

3.

4. df = pd.read_csv(file)

5. df

	tanggal_laporan	tahun	wilayah	jenis_energi	tipe_provider	status_operasional	kapasitas_terpasang_mw	produksi_energi_gwh	populasi_terlayani	biaya_operasional	emisi_karbon_terpangkas	laju_efisiensi	skor_investasi	target_tercapai
0	2022-11-15	2022.0	Bali	Hydro	NaN	NaN	405.813113	1241.543009	4.049588	IDR 254838419	11084.975509	63.510092	6.743301	No
1	2022-01-12	2022.0	NaN	Geothermal	Private	NaN	953.178591	1472.963412	3.662665	IDR 375905918	3175.423936	62.308642	5.133632	No
2	2023-07-24	2023.0	Sumatra	NaN	NaN	Maintenance	745.394245	2578.187440	2.173462	IDR 285706722	5526.275568	82.959294	9.680487	Yes
3	2023-11-04	2023.0	Nusa Tenggara	Hydro	Foreign NGO	Maintenance	618.725560	1086.012720	6.269033	IDR 50818265	10117.569234	96.712420	2.970806	Yes
4	2023-03-02	2023.0	Nusa Tenggara	Solar	Foreign NGO	Active	198.217708	2621.984086	NaN	IDR 100934316	7490.295496	79.103410	6.290708	No
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
6146	2023-04-03	2023.0	Java	NaN	NaN	Active	606.571549	1650.208180	2.556660	IDR 167299707	8666.908499	72.001911	NaN	No
6148	2024-01-03	2024.0	Jawa	Geothermal	Foreign NGO	Active	456.163967	860.984292	7.347755	IDR 283940031	9159.584066	94.333308	1.432658	No
6147	2023-01-07	2023.0	Java	Geothermal	Private	Broken	894.075604	2442.336870	1.872519	IDR 162273230	9267.059197	64.748807	8.760038	Yes
6143	2023-09-18	2023.0	Sumatra	NaN	NaN	Broken	189.360358	1230.006525	4.008637	IDR 149437687	5489.122844	62.778949	7.353336	No
6149	2022-03-06	2022.0	Sumatra	Hydro	Government	Active	831.408055	656.847128	8.873934	IDR 142898544	7706.543101	NaN	5.528423	No
5150 rows x 14 columns														

Gambar 1 Tampilan Dataset

Gambar 1 Tampilan Dataset

Gambar di atas adalah Tampilan Dataset dari Greindo.

a) Deskripsi Data

- Informasi Dasar

Tabel 3.2.2 3 Kode Melihat Informasi Dataset

1. df.info()

```
*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 5150 entries, 0 to 5149
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   tanggal_laporan                       5150 non-null   object
1   tahun                                 5150 non-null   float64
2   wilayah                               4892 non-null   object
3   jenis_energi                          4120 non-null   object
4   tipe_provider                         3390 non-null   object
5   status_operasional                    4635 non-null   object
6   kapasitas_terpasang_mw                5150 non-null   float64
7   produksi_energi_gwh                   5150 non-null   float64
8   populasi_terlayani                     4274 non-null   float64
9   biaya_operasional                     5150 non-null   object
10  emisi_karbon_terpangkas                 4534 non-null   float64
11  laju_efisiensi                          4540 non-null   float64
12  skor_investasi                         4532 non-null   float64
13  target_tercapai                       5098 non-null   object
dtypes: float64(7), object(7)
memory usage: 563.4+ KB
```

Gambar 2 Informasi Dataset

Berdasarkan Dataset di atas, dapat diketahui bahwa dataset Greindo Memiliki 5150 Baris dan 14 Kolom.

- Informasi Lanjutan

Berikut merupakan informasi lanjutan yang disajikan untuk memberikan pemahaman yang lebih rinci mengenai deskripsi setiap kolom pada dataset Greindo. Informasi ini mencakup jumlah data yang tersedia, tipe data, serta penjelasan dari masing-masing atribut, sehingga dapat membantu dalam proses eksplorasi, pembersihan, dan analisis data secara lebih terstruktur dan komprehensif.

1. tanggal_laporan, jumlah baris:5150, tipe data:object, deskripsi:tanggal pencatatan data.
2. tahun, jumlah baris:5150, tipe data data:float64, deskripsi:tahun pengamatan data energi.
3. wilayah, jumlah baris:4892, tipe data:object, deskripsi:nama wilayah ataupun pulau indonesia



4. jenis_energi, jumlah baris::4120, tipe data:object, deskripsi:sumber energi terbarukan yang digunakan dalam pembangkitan listrik
5. tipe_provider, jumlah baris:3390, tipe data:object, deskripsi:pengelola dari fasilitas
6. status_operasional jumlah baris:4635, tipe data:object, deskripsi: Kondisi fasilitas seperti aktif, Maintenance, ataupun broken
7. kapasitas_terpasang_mw, jumlah baris:5150, tipe data:float64, deskripsi:total kapasitas pembangkit listrik yang telah terpasang di wilayah tersebut berdasarkan sumber energi tertentu, diukur dalam satuan megawatt (MW)
8. produksi_energi_gwh, jumlah baris:5150, tipe data:float64, deskripsi:total energi listrik yang berhasil diproduksi dari sumber energi tersebut dalam satu periode tahun, diukur dalam satuan gigawatt-hour (GWh)
9. populasi_terlayani, jumlah baris:4274, tipe data:float64, deskripsi:jumlah penduduk yang mendapat akses (dalam juta).
10. biaya_operasional, jumlah baris:5150, tipe data:obejct, deskripsi:total biaya yang dikeluarkan untuk menjalankan dan merawat fasilitas
11. emisi_karbon_terpangkas, jumlah baris:4534, tipe data:float64, deskripsi:estimasi jumlah emisi CO2 (dalam satuan ton) yang berhasil dicegah



12. laju_efisiensi, jumlah baris:4540, tipe data:float64, deskripsi:persentase kinerja pembangkit dalam mengubah sumber daya alam menjadi listrik

13. skor_investasi, jumlah baris:4532, tipe data:float64, deskripsi:penilaian 1-10 mengenai kelayakan proyek untuk dikembangkan lebih lanjut berdasarkan risiko dan keuntungan di masa depan

14. target_tercapai, jumlah baris:5098, tipe data:object, deskripsi:status keberhasilan apakah produksi energi pada tanggal tersebut memenuhi target yang telah ditetapkan atau tidak oleh manajemen Greindo

- Informasi Statistik Deskriptif

Tabel 3.2.2 4 Kode Melihat Deskriptif Statistik Dataset

1. df.describe(include='all')														
	tanggal_laporan	tahun	wilayah	jenis_energi	tipe_provider	status_operasional	kapasitas_terpasang_mw	produksi_energi_gwh	populasi_terlayani	biaya_operasional	emisi_karbon_terpangkas	laju_efisiensi	skor_investasi	target_tercapai
count	5150	5150.000000	4892	4120	3390	4635	5150.000000	5150.000000	4274.000000	5150	4534.000000	4540.000000	4532.000000	5098
unique	800	NaN	9	6	3	3	NaN	NaN	NaN	5000	NaN	NaN	NaN	2
top	2023-07-24	NaN	Bali	Solar	Private	Active	NaN	NaN	NaN	IDR 430177812	NaN	NaN	NaN	No
freq	17	NaN	665	960	1159	1554	NaN	NaN	NaN	2	NaN	NaN	NaN	2567
mean	NaN	2022.654951	NaN	NaN	NaN	NaN	908.999184	1527.389961	5.222767	NaN	7897.942852	79.502093	5.497102	NaN
std	NaN	0.646764	NaN	NaN	NaN	NaN	6193.785265	830.334370	2.875594	NaN	4189.071049	13.147844	2.598042	NaN
min	NaN	2022.000000	NaN	NaN	NaN	NaN	50.011053	100.153198	-5.000000	NaN	500.697796	60.004189	1.000050	NaN
25%	NaN	2022.000000	NaN	NaN	NaN	NaN	284.330494	815.439215	2.811890	NaN	4261.635426	69.528746	3.224526	NaN
50%	NaN	2023.000000	NaN	NaN	NaN	NaN	527.468727	1510.741472	5.239458	NaN	7961.922993	78.983319	5.517111	NaN
75%	NaN	2023.000000	NaN	NaN	NaN	NaN	764.071315	2234.404108	7.746725	NaN	11498.412955	88.319993	7.718630	NaN
max	NaN	2024.000000	NaN	NaN	NaN	NaN	99999.000000	2998.565050	9.998149	NaN	14998.564167	150.500000	9.998104	NaN

Gambar 3 Deskriptif Statistik Dataset

Dapat di lihat pada setiap kolom itu jumlah data nya masih bervariasi dan tidak semua nya memiliki baris yang lengkap sampai 5150 yang berarti data tersebut terdapat missing values. Ini menunjukkan data yang tidak konsisten dan perlu di bersihkan.

Statistik Variabel Kategori

- tanggal_laporan, terdapat 800 nilai unik nya dan tanggal yang paling sering muncul ialah 2023-07-24 sebanyak 17 kali.
- wilayah, terdapat 9 nilai unik dan wilayah yang paling sering muncul ialah Bali yaitu sebanyak 665 kali.



3. jenis_energi, terdapat 6 jenis energi dan energi yang paling banyak di gunakan ialah solar dan muncul sebanyak 960 kali.
4. tipe_provider, terdapat 3 tipe provider (pemerintah, swasta dan asing dan swasta adalah yang terbanyak dengan muncul sebanyak 1159 kali.
5. status_operasional, terdapat 3 kategori (Aktif, Maintenance, Broken) yang dimana aktif paling banyak muncul sebanyak 1554 kali.
6. biaya_operasioal, terdapat 5000 nilai unik dan yang paling banyak muncul ialah IDR 430177812 sebanyak 2 kali.
7. target_tercapai, terdapat 2 kategori keberhasilan (Yes and No) dan 'No' adalah yang paling sering muncul sebanyak 2567 kali.

Statistik Variabel Numerik

1. Kapasitas_terpasang_mw, memiliki mean 908.999184 dengan nilai min nya 50.011053 sampai dengan 9999.000000 max nya dan std nya 6193.785265.
2. produksi_energi_gwh, memiliki mean sebesar 1527.389961 dengan nilai min nya sebesar 100.153198 sampai dengan 2998.565050 nilai max nya dan std nya ialah 830.334370.
3. populasi_terlayani, memiliki mean sebesar 5.222767 dengan nilai min nya sebesar -5000000 sampai dengan max nya sebesar 9.998149 dan std nya sebesar 2.875594.
4. emisi_karbon_terpangkas, memiliki mean sebesar 7897.942852 dengan nilai min nya sebesar 500.697796 sampai dengan 14998.564167 max nya dan nilai std nya sebesar 4189.071049.
5. laju_efisiensi, memiliki mean sebesar 79.502093 dengan nilai min nya sebesar 60.004189 sampai dengan 150.500000 nilai max nya dan nilai stdnya sebesar 13.147844



6. skor_investasi, memiliki mean sebesar 5.497102 dengan nilai min nya sebesar 1.000050 sampai dengan 9.998104 nilai max nya dan nilai std nya sebesar 2.598042.

b) Verifikasi Kualitas Data

- Incosistent Values

Tabel 3.2.2 5 Kode Cek Tipe Data

1. df.dtypes	
***	@
tanggal_laporan	object
tahun	float64
wilayah	object
jenis_energi	object
tipe_provider	object
status_operasional	object
kapasitas_terpasang_mw	float64
produksi_energi_gwh	float64
populasi_terlayani	float64
biaya_operasional	object
emisi_karbon_terpangkas	float64
laju_efisiensi	float64
skor_investasi	float64
target_tercapai	object
dtype: object	

Gambar 4 Tipe Data

Berdasarkan hasil pengecekan tipe data pada setiap kolom, ditemukan beberapa kolom yang memiliki tipe data yang tidak sesuai sehingga perlu diperbaiki agar proses analisis data ke depannya menjadi lebih mudah, akurat, dan efisien. Kolom tanggal_laporan saat ini bertipe data object, padahal berdasarkan strukturnya kolom ini merepresentasikan informasi tanggal yang mencakup tahun, bulan, dan hari, sehingga tipe data yang lebih tepat adalah datetime agar memudahkan analisis berbasis waktu. Selanjutnya, kolom tahun masih bertipe float, sedangkan nilai tahun seharusnya berupa bilangan bulat tanpa desimal, sehingga tipe data yang sesuai adalah integer (int). Selain itu, kolom biaya_operasional juga bertipe object, padahal berisi nilai biaya yang bersifat numerik; oleh karena itu, tipe data yang tepat adalah float, dengan catatan perlu



dilakukan pembersihan data terlebih dahulu jika terdapat format teks seperti “IDR”. Secara keseluruhan, penyesuaian tipe data ini sangat penting untuk memastikan data dapat diolah dengan benar serta mendukung analisis lanjutan tanpa kendala.

Tabel 3.2.2 6 Cek Data Kolom Wilayah

```
1. print(df['wilayah'].unique())
```

```
***  ['Bali' nan 'Sumatra' 'Nusa Tenggara' 'Sulawesi' 'Papua' 'jawa' 'Java'
      'Kalimantan' 'JAVA']
```

Gambar 5 Data Kolom Wilayah

Berdasarkan hasil pengecekan nilai unik pada kolom wilayah, terlihat bahwa terdapat beberapa inkonsistensi dalam penulisan data. Pertama, terdapat perbedaan penulisan huruf besar dan kecil pada wilayah yang sama, seperti 'jawa', 'Java', dan 'JAVA'. Ketiga nilai tersebut sebenarnya merujuk pada entitas yang sama, namun ditulis dengan format berbeda. Hal ini dapat menyebabkan kesalahan dalam analisis. Kedua, terdapat perbedaan bahasa dalam penulisan, yaitu 'jawa' (Bahasa Indonesia) dan 'Java' (Bahasa Inggris). Ini juga termasuk inkonsistensi yang perlu diseragamkan agar data lebih rapi dan mudah dianalisis. Sementara itu, nilai lain seperti 'Bali', 'Sumatra', 'Nusa Tenggara', 'Sulawesi', 'Papua', dan 'Kalimantan' sudah terlihat konsisten. Secara keseluruhan, kolom wilayah belum sepenuhnya bersih karena adanya inkonsistensi penulisan, sehingga diperlukan proses data cleaning seperti standarisasi huruf (misalnya semua menjadi huruf kecil atau kapital di awal) dan penyamaan bahasa agar analisis menjadi lebih akurat.

Tabel 3.2.2 7 Kode Cek Kolom Jenis Energi

```
1. print(df['jenis_energi'].unique())
```

```
***  ['Hydro' 'Geothermal' nan 'Solar' 'Wind' 'S_Energy' 'Hydro Power']
```

Gambar 6 Data Kolom Energi

Pertama, terdapat nilai yang merujuk pada jenis energi yang sama namun ditulis berbeda, seperti 'Hydro' dan 'Hydro Power'. Keduanya memiliki makna yang sama, sehingga sebaiknya diseragamkan agar tidak dianggap sebagai dua kategori berbeda dalam analisis. Kedua, terdapat nilai 'S_Energy' yang terlihat tidak konsisten atau kurang jelas dibandingkan dengan kategori lain seperti 'Solar', 'Wind', dan 'Geothermal'. Kemungkinan besar ini merupakan penulisan yang tidak standar atau singkatan dari 'Solar Energy', sehingga perlu dikonfirmasi dan diperbaiki agar lebih



jelas. Sementara itu, kategori lain seperti 'Solar', 'Wind', dan 'Geothermal' sudah cukup konsisten dan jelas. Secara keseluruhan, kolom jenis_energi masih memerlukan proses data cleaning, terutama dalam hal standarisasi penamaan kategori dan penanganan missing value, agar hasil analisis menjadi lebih akurat dan tidak bias akibat perbedaan penulisan.

- Missing Values

Tabel 3.2.2 8 Kode Cek Missing Values

1. `pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])`

*** Null Ratio in %	
tanggal_laporan	0.000000
tahun	0.000000
wilayah	5.009709
jenis_energi	20.000000
tipe_provider	34.174757
status_operasional	10.000000
kapasitas_terpasang_mw	0.000000
produksi_energi_gwh	0.000000
populasi_terlayani	17.009709
biaya_operasional	0.000000
emisi_karbon_terpangkas	11.961165
laju_efisiensi	11.844660
skor_investasi	12.000000
target_tercapai	1.009709

Gambar 7 Missing Values

Secara umum, terdapat beberapa kolom yang sudah sangat bersih tanpa missing value, seperti tanggal_laporan, tahun, kapasitas_terpasang_mw, produksi_energi_gwh, dan biaya_operasional. Hal ini menunjukkan bahwa data inti yang bersifat waktu dan metrik utama produksi sudah lengkap dan dapat langsung digunakan untuk analisis tanpa perlu penanganan tambahan.

Namun, terdapat beberapa kolom dengan tingkat missing value yang cukup signifikan, terutama pada tipe_provider (34%) dan jenis_energi (20%). Ini menunjukkan bahwa informasi terkait sumber dan karakteristik energi belum terdokumentasi dengan baik. Dampaknya, analisis



yang melibatkan perbandingan antar provider atau jenis energi berpotensi menjadi kurang representatif jika missing value tidak ditangani.

Selain itu, kolom seperti populasi_terlayani (17%), skor_investasi (12%), laju_efisiensi (11.8%), dan emisi_karbon_terpangkas (12%) juga memiliki missing value dalam jumlah menengah. Ini mengindikasikan bahwa data yang bersifat evaluatif dan dampak (impact metrics) cenderung lebih sering tidak lengkap dibandingkan data operasional utama. Sementara itu, kolom wilayah (5%) dan status_operasional (10%) memiliki missing value yang relatif lebih kecil, sehingga masih cukup aman digunakan dengan sedikit penanganan. Terakhir, kolom target_tercapai hanya memiliki missing value sekitar 1%, yang berarti hampir seluruh data sudah memiliki label pencapaian. Ini sangat baik, terutama jika kolom ini akan digunakan sebagai target dalam analisis atau modeling.

- Duplicated Values

Tabel 3.2.2 9 Kode Cek Duplicated Values

1. df[df.duplicated()]														
id	tanggal_laporan	tahun	wilayah	jenis_energi	tipe_provider	status_operasional	kapasitas_terpasang_mw	produksi_energi_gwh	populasi_terlayani	biaya_operasional	emisi_karbon_terpangkas	laju_efisiensi	skor_investasi	target_tercapai
6002	2024-02-05	2024.0	Sumatra	Geothermal	Government	Active	347.139090	2348.687092	1.237826	IDR 116466601	NaN	71.291268	5.534947	Yes
6004	2023-10-18	2023.0	Nusa Tenggara	Geothermal	Foreign NGO	Broken	399.021192	775.854245	5.148086	IDR 389368873	7201.315848	68.977895	9.877948	No
6012	2023-07-18	2023.0	JAWA	Wind	NaN	Broken	955.174266	1071.524853	1.190497	IDR 120447036	NaN	97.688405	3.980433	Yes
6018	2023-08-02	2023.0	Jawa	Hydro	Foreign NGO	Broken	577.440771	1153.871403	8.809669	IDR 260317658	3732.323494	87.621518	4.200115	No
6026	2023-03-26	2023.0	Sulawesi	Solar	Government	Active	246.642950	407.777058	9.889704	IDR 120312677	7723.442027	97.480339	NaN	Yes
6028	2022-09-10	2022.0	Bali	Wind	Foreign NGO	Broken	601.902861	677.338707	1.525104	IDR 470965894	13053.139285	66.257647	2.390842	Yes
6029	2024-02-29	2024.0	Bali	Wind	Private	Active	549.196792	1456.762632	4.026663	IDR 26039826	9759.261782	60.755273	NaN	No
6036	2023-06-17	2023.0	Bali	Solar	NaN	Broken	681.803190	1495.694460	7.024802	IDR 456946591	11740.564100	NaN	1.901955	No
6037	2024-02-20	2024.0	Jawa	Geothermal	NaN	Maintenance	879.298544	2629.944234	6.116808	IDR 241409095	NaN	NaN	7.864789	Yes
6038	2023-10-25	2023.0	Kalimantan	Geothermal	Foreign NGO	Maintenance	672.415029	2466.497157	5.555139	IDR 349845603	11697.996387	72.156613	8.393761	No
6039	2022-07-25	2022.0	Bali	NaN	Government	Broken	128.999994	2428.832022	6.034241	IDR 237007908	8813.263143	92.576912	6.413442	Yes
6043	2024-01-23	2024.0	Jawa	Hydro	Private	Maintenance	74.405163	2242.456284	1.999499	IDR 96834815	10148.143939	93.191219	4.839718	Yes
6046	2024-02-16	2024.0	Jawa	Hydro	NaN	Broken	321.470408	1543.820623	6.030153	IDR 243228224	11125.040990	76.888774	8.776078	Yes
6047	2023-11-23	2023.0	Nusa Tenggara	Wind	Government	Maintenance	386.099701	2814.764157	9.384039	IDR 380247779	802.139981	83.250356	6.096300	Yes
6048	2024-03-05	2024.0	Jawa	Hydro	Private	Maintenance	161.649934	2420.398960	5.298049	IDR 93083417	8092.208309	88.163802	6.193987	Yes
6066	2023-03-05	2023.0	JAWA	S_Energy	Private	Maintenance	203.294661	658.486734	9.828219	IDR 338953675	5454.629937	82.359998	8.289757	No
6067	2022-10-19	2022.0	Sulawesi	Hydro	Foreign NGO	Broken	520.389201	2806.295459	9.049841	IDR 324036915	9421.347836	82.768688	9.163073	Yes
6061	2022-09-23	2022.0	Sumatra	NaN	NaN	Broken	208.605434	2952.432169	5.610269	IDR 323404856	14079.322223	74.309293	2.535925	No
6062	2022-08-13	2022.0	Sumatra	S_Energy	Foreign NGO	Maintenance	538.390670	1950.209382	9.257532	IDR 412117608	8125.093659	96.681866	3.741275	Yes
6063	2022-10-10	2022.0	Papua	Hydro	NaN	Maintenance	287.185505	159.164671	4.812363	IDR 480181173	5967.503170	90.477244	4.487320	No
6066	2024-02-27	2024.0	Sulawesi	Hydro	NaN	Broken	208.989181	510.672917	8.412009	IDR 100719033	5263.234336	93.169414	2.782969	Yes
6070	2023-08-27	2023.0	Sulawesi	Solar	Foreign NGO	Active	234.169915	2817.152836	5.777427	IDR 495197260	14051.200833	60.415279	5.864323	Yes
6071	2023-03-10	2023.0	Jawa	Geothermal	Private	Maintenance	909.141786	1838.154300	3.086352	IDR 256668013	7875.782165	73.977018	1.923152	No
6079	2022-11-13	2022.0	Kalimantan	Solar	Government	Broken	88.736384	690.251134	5.232432	IDR 295152384	NaN	96.352131	8.396649	No
6080	2022-01-30	2022.0	JAWA	Wind	Foreign NGO	Active	711.175496	1413.191935	5.555056	IDR 420706201	552.261478	NaN	5.736991	No
6082	2024-03-01	2024.0	Nusa Tenggara	Wind	Foreign NGO	Maintenance	582.159774	2468.700772	5.980760	IDR 155859269	6575.955548	87.832027	NaN	Yes
6088	2022-11-16	2022.0	Jawa	Hydro	Government	Active	618.004080	1365.113476	5.486874	IDR 241165904	NaN	NaN	1.243546	Yes
6089	2024-02-25	2024.0	Bali	Solar	Private	Broken	596.264657	2480.139938	4.772409	IDR 495294920	13369.910705	65.631757	9.054423	No
6089	2024-02-09	2024.0	Jawa	Hydro	NaN	Active	997.746883	800.368058	8.886712	IDR 422194931	12061.050589	61.594274	9.743862	Yes
6098	2023-02-21	2023.0	Jawa	Wind	Foreign NGO	Active	527.499680	1494.730663	1.441036	IDR 303785502	10872.531809	70.504401	8.038610	Yes
6100	2022-03-13	2022.0	JAWA	Wind	Government	Broken	356.875978	1857.443507	1.106347	IDR 90922858	11660.130083	69.309248	NaN	No

Gambar 8 Duplicated Values

Berdasarkan hasil pengecekan duplicated value, dapat disimpulkan bahwa dataset mengandung baris data yang benar-benar identik seperti duplikasi, di mana seluruh nilai pada setiap kolom sama persis dengan baris lainnya yang sudah muncul sebelumnya. Baris yang



ditampilkan dalam hasil tersebut merupakan kemunculan kedua dan seterusnya dari data yang sama, sehingga menunjukkan adanya pencatatan data yang berulang. Kondisi ini mengindikasikan bahwa dalam proses pengumpulan atau pengolahan data, terdapat kemungkinan duplikasi input atau penggabungan data tanpa proses deduplikasi.

Keberadaan duplikasi ini berpotensi menyebabkan distorsi dalam analisis, seperti perhitungan total, rata-rata, maupun distribusi yang menjadi tidak akurat karena data yang sama dihitung lebih dari satu kali. Oleh karena itu, sebelum melakukan analisis lebih lanjut, penting untuk melakukan proses pembersihan data dengan menghapus duplikasi agar hasil yang diperoleh lebih valid dan representatif.

- Outliers Values

Tabel 3.2.2 10 Kode Cek Outliers

```
1. results = []

2. cols = df.select_dtypes(include=['float64', 'int64'])

3. for col in cols:
4.     q1 = df[col].quantile(0.25)
5.     q3 = df[col].quantile(0.75)
6.     iqr = q3 - q1
7.     lower_bound = q1 - 1.5*iqr
8.     upper_bound = q3 + 1.5*iqr
9.     outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
10. percent_outliers = (len(outliers)/len(df))*100
11. results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

12. # Dataframe dari list hasil
13. results_df = pd.DataFrame(results)
14. results_df.set_index('Kolom', inplace=True)
15. results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

16. # Tampilkan dataframe
17. display(results_df)
```

*** Kolom Persentase Outliers	
tahun	0.000000
kapasitas_terpasang_mw	0.388350
produksi_energi_gwh	0.000000
populasi_terlayani	0.504854
emisi_karbon_terpangkas	0.000000
laju_efisiensi	0.970874
skor_investasi	0.000000

Gambar 9 Outliers Values

Berdasarkan hasil pengecekan outliers value, dapat disimpulkan bahwa secara umum dataset memiliki jumlah outlier yang relatif kecil pada sebagian besar kolom, namun terdapat beberapa kolom yang perlu diperhatikan. Kolom seperti tahun, produksi_energi_gwh, emisi_karbon_terpangkas, dan skor_investasi tidak memiliki outlier (0%), yang menunjukkan bahwa distribusi data pada kolom-kolom tersebut cukup stabil dan berada dalam rentang yang wajar. Hal ini menandakan bahwa data pada kolom tersebut sudah konsisten dan tidak memerlukan penanganan khusus terkait outlier. Namun, terdapat beberapa kolom yang memiliki outlier meskipun dalam proporsi kecil, yaitu kapasitas_terpasang_mw (0.38%), populasi_terlayani (0.50%), dan terutama laju_efisiensi (0.97%) yang memiliki persentase outlier paling tinggi di antara yang lain.

Outliers pada kolom kapasitas_terpasang_mw (0.38%) tidak perlu ditangani secara khusus karena nilai-nilai ekstrem yang muncul masih dapat dianggap wajar dalam konteks data energi. Secara alami, kapasitas pembangkit listrik memang memiliki rentang yang sangat bervariasi, mulai dari skala kecil hingga skala besar tergantung pada jenis pembangkit, teknologi yang digunakan, serta wilayah operasionalnya. Oleh karena itu, nilai yang terlihat jauh lebih tinggi dibandingkan mayoritas data bukan berarti kesalahan, melainkan bisa merepresentasikan pembangkit dengan kapasitas besar.

Outliers pada kolom laju efisiensi juga tidak perlu ditangani secara khusus karena variasi nilai yang muncul masih tergolong wajar dan dapat dijelaskan secara kontekstual. Laju efisiensi dalam sektor energi sangat dipengaruhi oleh berbagai faktor, seperti jenis sumber energi yang digunakan, teknologi pembangkit, serta kondisi operasional di lapangan. Perbedaan efisiensi antar pembangkit merupakan hal yang umum, sehingga nilai yang lebih tinggi atau lebih rendah dari mayoritas data belum tentu menunjukkan kesalahan. Selama tidak terdapat nilai yang tidak



logis, seperti efisiensi bernilai negatif atau melebihi batas wajar misalnya di atas 100% jika dalam bentuk persentase, maka data tersebut masih dapat dianggap valid.

Oleh karena itu, mempertahankan outliers pada kolom laju efisiensi justru penting agar analisis tetap mencerminkan kondisi nyata dan keberagaman performa antar pembangkit energi. Secara keseluruhan, jumlah outlier yang rendah menunjukkan bahwa kualitas data cukup baik dan tidak banyak nilai ekstrem yang menyimpang, sehingga tidak akan terlalu mengganggu analisis secara umum.

c) Eksplorasi Data (EDA)

- Comparison

Tabel 3.2.2 11 Kode Bar Chart Perbandingan Kapasitas Antar Wilayah


```
1. #Membandingkan kapasitas terpasang antar wilayah
2. import matplotlib.pyplot as plt

3. VARIABEL =
   df.groupby('wilayah')['kapasitas_terpasang_mw'].sum().sort_values(ascending=False).head(10)

4. plt.figure(figsize=(10, 6))
5. plt.bar(VARIABEL.index, VARIABEL.values, color='skyblue')

6. plt.xlabel('Wilayah')
7. plt.ylabel('Total Kapasitas (MEGA WATT)')
8. plt.title('Top 10 Wilayah berdasarkan Kapasitas')

9. plt.xticks(rotation=45, ha='right')
10. plt.tight_layout()
11. plt.show()
```



Gambar 10 Perbandingan Kapasitas Antar Wilayah

Berdasarkan visualisasi tersebut, terlihat perbandingan kapasitas energi pada masing-masing wilayah. Secara umum, persebaran kapasitas energi masih belum merata. Beberapa wilayah memiliki kapasitas yang jauh lebih besar dibandingkan wilayah lainnya.

Ketimpangan ini dapat dipengaruhi oleh beberapa faktor, salah satunya adalah perbedaan luas wilayah. Wilayah dengan cakupan geografis yang lebih luas cenderung membutuhkan kapasitas energi yang lebih besar untuk memenuhi kebutuhan penduduk serta aktivitas industri di dalamnya. Selain itu, faktor lain seperti jumlah penduduk, tingkat urbanisasi, dan perkembangan infrastruktur juga dapat memengaruhi besarnya kapasitas energi terpasang.

Selain itu, ditemukan adanya data wilayah yang duplikat contohnya wilayah "Jawa" namun ada juga data lain yang konteksnya sama seperti wilayah "java" dan "JAVA". Keberadaan data duplikat ini dapat menyebabkan distorsi dalam analisis, seperti perhitungan kapasitas yang menjadi tidak akurat (overcounting). Hal ini berpotensi menghasilkan interpretasi yang keliru terhadap kondisi sebenarnya.

Duplikasi data tersebut kemungkinan terjadi akibat inkonsistensi dalam proses input data, perbedaan penulisan nama wilayah, atau penggabungan data dari berbagai sumber yang belum melalui proses pembersihan (data cleaning) secara optimal.



Oleh karena itu, diperlukan tahap preprocessing data yang lebih teliti, seperti normalisasi penamaan wilayah dan penghapusan data duplikat, agar hasil analisis yang diperoleh menjadi lebih valid dan dapat diandalkan.

Tabel 3.2.2 12 Kode Bar Chart Perbandingan Produksi Energi Antar Wilayah


```
1. import matplotlib.pyplot as plt

2. VARIABEL =
    df.groupby('wilayah')['produksi_energi_gwh'].sum().sort_values(ascending=False).head(10)

3. plt.figure(figsize=(10, 6))
4. plt.bar(VARIABEL.index, VARIABEL.values, color='skyblue')

5. plt.xlabel('Wilayah')
6. plt.ylabel('Performa Produksi Energi Antar Wilayah (GIGA WATT per HOURS)')
7. plt.title('Top 10 Wilayah berdasarkan Performa Produksi')

8. plt.xticks(rotation=45, ha='right')
9. plt.tight_layout()
10. plt.show()
```

Gambar 11 Perbandingan Produksi Energi Antar Wilayah

Berdasarkan visualisasi perbandingan wilayah dengan performa produksi energi (dalam satuan gigawatt per jam) yang dapat dilihat pada visualisasi di atas performanya (1.0 gwh, 0.8 gwh, 0.6, 0.4 gwh, 0.2 gwh) terlihat bahwa produksi energi antar wilayah cenderung relatif merata. Hal ini menunjukkan bahwa sistem penyediaan energi telah berjalan cukup seimbang, kemungkinan didukung oleh perencanaan distribusi energi yang terpusat serta adanya jaringan interkoneksi antar wilayah, sehingga suplai energi dapat saling melengkapi sesuai kebutuhan.

Selain itu, pemerataan ini juga dapat dipengaruhi oleh tingkat permintaan energi yang tidak jauh berbeda di setiap wilayah, serta adanya standarisasi infrastruktur pembangkit yang membuat kapasitas produksi menjadi relatif seragam.

Namun demikian, perlu diperhatikan bahwa hasil ini juga dapat dipengaruhi oleh proses agregasi data yang cenderung menyamarkan perbedaan kecil antar wilayah. Di sisi lain, ditemukan adanya data wilayah yang duplikat seperti wilayah "Jawa" yang konteksnya itu sama dengan data wilayah "java" dan "JAVA", yang berpotensi menyebabkan distorsi dalam analisis, seperti perhitungan produksi yang menjadi tidak akurat akibat penggandaan data.

Duplikasi tersebut kemungkinan terjadi akibat inkonsistensi dalam proses input, perbedaan penulisan nama wilayah, atau penggabungan data dari berbagai sumber tanpa proses



pembersihan data yang optimal. Oleh karena itu, diperlukan tahap data cleaning, seperti penghapusan duplikat dan standarisasi penamaan wilayah, agar hasil analisis yang diperoleh lebih akurat dan dapat merepresentasikan kondisi sebenarnya.

Tabel 3.2.2 13 Kode Bar Chart Perbandingan Produksi Energi Berdasarkan Provider


```
1. import matplotlib.pyplot as plt

2. VARIABEL =
    df.groupby('tipe_provider')['produksi_energi_gwh'].sum().sort_values(ascending=False
    ).head(5)

3. plt.figure(figsize=(10, 6))
4. plt.bar(VARIABEL.index, VARIABEL.values, color='skyblue')

5. plt.xlabel('Tipe Provider')
6. plt.ylabel('Performa Produksi (GIGA WATT per HOURS)')
7. plt.title('Perbandingan Performa Antar Provider Dengan Produksi Energi')

8. plt.xticks(rotation=45, ha='right')
9. plt.tight_layout()
10. plt.show()
```



Gambar 12 Perbandingan Produksi Energi Berdasarkan Tipe Provider


Berdasarkan visualisasi tersebut, provider swasta menunjukkan performa produksi energi tertinggi dengan nilai sekitar 1.8 GWh, yang mengindikasikan bahwa sektor ini memiliki efisiensi operasional, kapasitas produksi, serta kemampuan investasi yang lebih unggul dibandingkan sektor lainnya. Sementara itu, provider pemerintah (government) berada pada posisi terendah dengan produksi sekitar 1.6 GWh, yang kemungkinan dipengaruhi oleh keterbatasan anggaran, proses birokrasi, atau fokus yang tidak semata-mata pada peningkatan produksi melainkan juga pada pelayanan publik. Di sisi lain, provider asing atau NGO berada di posisi tengah, menunjukkan bahwa meskipun cukup efisien, skala operasional mereka tidak sebesar sektor swasta karena cenderung berorientasi pada tujuan sosial atau keberlanjutan. Meskipun terdapat perbedaan performa antar provider, selisih produksi yang relatif kecil menunjukkan bahwa kontribusi masing-masing sektor tetap signifikan dan kompetisi yang terjadi cukup seimbang, sehingga kolaborasi antar sektor menjadi kunci dalam meningkatkan produksi energi secara keseluruhan.



- Composition

Tabel 3.2.2 14 Kode Pie Chart Proporsi Jenis Energi

```
1. jenis_energi =  
    df.groupby('jenis_energi')['produksi_energi_gwh'].sum().sort_values(ascending=False)  
2. produksi_energi_gwh = jenis_energi.head(6)  
  
3. plt.figure(figsize=(10, 8))  
4. produksi_energi_gwh.plot(kind='pie', autopct='%1.1f%%', startangle=140,  
    colors=plt.cm.Paired.colors)  
5. plt.title('Proporsi Jenis Energi ')  
6. plt.ylabel('')  
7. plt.axis('equal')  
8. plt.show()
```




Dari visualisasi di atas dapat dilihat presentase setiap jenis energi yang diproduksi lebih banyak kontribusinya pada bagian mana. Dapat diketahui energi yang paling banyak kontribusi ialah Geothermal dan Wind dengan presentase tertinggi sebesar 22.9%, lalu diikuti dengan energi Solar 22.7% dan Hydro 21.9% yang berarti keempat energi tersebut menjadi pilar utama dalam produksi energi ini, sekaligus memperlihatkan bahwa penyebaran setiap jenis energi ini masih bisa dibilang cukup merata dan seimbang, karena tidak ada satu jenis energi yang paling mencolok namun hampir semua presentase kontribusinya itu tidak jauh berbeda selisihnya. Di sisi lain terdapat dua energi yang kontribusinya itu sangat kecil yaitu S_Energy yang dimana energi ini satu konteks dengan energi Solar dengan presentase 4.9% dan Hydro Power yang dimana energi satu konteks juga dengan energi Hydro dengan presentase 4.7% yang mengindikasikan bahwa adanya kesalahan dalam penginputan data, sehingga hasilnya belum optimal. Secara keseluruhan, kondisi ini menunjukkan sistem energi yang cukup stabil dan tidak bergantung pada satu sumber

saja, namun tetap terdapat peluang pengembangan pada jenis energi dengan proporsi rendah untuk meningkatkan kontribusinya di masa depan.

Tabel 3.2.2 15 Kode Pie Chart Proporsi Status Operasional

1. `plt.figure(figsize=(10, 6)) # ukuran`
2. `plt.pie(df['status_operasional'].value_counts(),
labels=df['status_operasional'].value_counts().index, autopct='%1.1f%%',
colors=['lightcoral', 'lightblue', 'lightgreen', 'gold']) # colors (warna)`
3. `plt.title('Proporsi Status Operasional') # Judul`
4. `plt.show()`



Gambar 14 Proporsi Status Operasional


Dari hasil visualisasi Pie Chart di atas dapat diketahui bahwa sebagian besar fasilitas berada dalam kondisi aktif dengan persentase sebesar 33,5%. Hal ini menunjukkan bahwa mayoritas infrastruktur energi masih beroperasi dengan baik dan mampu berkontribusi terhadap produksi energi. Namun demikian, terdapat porsi yang cukup besar pada fasilitas yang berada dalam kondisi maintenance (33,4%) dan rusak/broken (33,1%), yang jika digabungkan mencapai hampir 67% dari total fasilitas. Hal ini menunjukkan bahwa meskipun banyak fasilitas masih beroperasi, sebagian besar lainnya belum optimal, sehingga perlu peningkatan dalam perawatan dan perbaikan agar kinerja operasional lebih maksimal.



- Distribution

Tabel 3.2.2 16 Kode Distribusi Kapasitas Terpasang

```
1. plt.figure(figsize=(10, 6))
2. sns.histplot(df['kapasitas_terpasang_mw'], bins=20, kde=True)
3. plt.title('Distribusi Kapasitas Energi Terpasang')
4. plt.xlabel('Keterangan X')
5. plt.ylabel('Frekuensi')
6. plt.show()
```




Gambar 15 Distribusi Kapasitas Terpasang

Dari visualisasi tersebut dapat di ketahui insight nya bahwa distribusi data itu masih sangat tidak merata karena distribusi tersebut lebih condong frekuensi nya ke pada bagian kanan grafik, sementara pada bagian kiri mulai semakin sedikit yang berarti distribusi data tersebut tidak normal dan dapat di indikasikan bahwa data tersebut juga terdapat outlier atau nilai ekstrem pada sisi kiri yang memiliki rentang jauh lebih besar namun dengan frekuensi yang rendah.

Tabel 3.2.2 17 Kode Distribusi Produksi Energi

```
1. plt.figure(figsize=(10, 6))
2. sns.histplot(df['produksi_energi_gwh'], bins=20, kde=True)
```

3. `plt.title('Distribusi Produksi Energi')`
4. `plt.xlabel('Produksi Energi')`
5. `plt.ylabel('Frekuensi')`
6. `plt.show()`




Gambar 16 Distribusi Produksi Energi

Berdasarkan Visualisasi data di atas dapat disimpulkan bahwa distribusi data penyebaran produksi energi terlihat menyebar secara merata sepanjang rentang nilainya, tanpa adanya nilai yang memuncak ataupun sangat rendah. Pola ini menunjukkan berarti frekuensi data nya itu relatif dan seimbang tanpa ada nya nilai ekstrem.

Tabel 3.2.2 18 Kode Distribusi Populasi Terlayani


1. `plt.figure(figsize=(10, 6))`
2. `sns.histplot(df['populasi_terlayani'], bins=20, kde=True)`
3. `plt.title('Distribusi Populasi Terlayani')`
4. `plt.xlabel('Jumlah Populasi Terlayani')`
5. `plt.ylabel('Frekuensi')`
6. `plt.show()`



Berdasarkan Visualisasi di atas dapat diketahui bahwa data sebagian besar condong ke kiri dengan rentang nilai 1 - 10 juta penduduk yang berarti persebarannya itu cukup relatif dan merata dalam rentang tersebut karena tidak ada nilai yang tiba-tiba menjolak tinggi, namun ada nilai yang menjolak rendah pada bagian rentang kanan yaitu mulai menurun sangat jauh mencapai -4 yang berarti ini termasuk outlier, karena tidak mungkin secara logika nilai populasi itu ada yang negatif, kemungkinan ini ada kesalahan input data dan pastinya untuk kedepannya perlu di cleaning.

Tabel 3.2.2 19 Kode Distribusi Emisi Karbon Terpangkas


1. `plt.figure(figsize=(10, 6))`
2. `sns.histplot(df['emisi_karbon_terpangkas'], bins=20, kde=True)`
3. `plt.title('Distribusi Emisi Karbon Yang Terpangkas')`
4. `plt.xlabel('Jumlah Emisi')`
5. `plt.ylabel('Frekuensi')`
6. `plt.show()`



Dari visualisasi histogram di atas, terlihat bahwa data memiliki penyebaran yang relatif merata di seluruh rentang nilai, tanpa adanya puncak dominan pada interval tertentu. Data di atas cenderung datar yang berarti distribusi data tidak mengalami kemiringan yang signifikan, sehingga dapat dikatakan bahwa data cukup seimbang. Selain itu juga tidak ditemukan adanya outlier ekstrem yang menyimpang jauh dari distribusi utama. Kondisi ini menunjukkan bahwa data emisi karbon yang terpangkas tergolong stabil dan representatif untuk analisis lebih lanjut.

Tabel 3.2.2 20 Kode Distribusi Laju Efisiensi

1. `plt.figure(figsize=(10, 6))`
2. `sns.histplot(df['laju_efisiensi'], bins=20, kde=True)`
3. `plt.title('Distribusi Laju Efisiensi Energi')`
4. `plt.xlabel('Jumlah Laju Efisiensi')`
5. `plt.ylabel('Frekuensi')`
6. `plt.show()`




Gambar 19 Distribusi Laju Efisiensi

Dari visualisasi histogram di atas, terlihat bahwa sebagian besar data terkonsentrasi pada rentang nilai sekitar 60 hingga 95, yang menunjukkan bahwa mayoritas entitas memiliki tingkat efisiensi yang relatif seragam pada kisaran tersebut. Namun, terdapat sejumlah kecil nilai ekstrem di atas 100 hingga sekitar 150, yang menyebabkan distribusi menjadi miring ke kanan. Keberadaan nilai-nilai tinggi ini mengindikasikan adanya outlier atau entitas dengan efisiensi yang jauh lebih tinggi dibandingkan mayoritas data.

Tabel 3.2.2 21 Kode Skor Investasi

1. `plt.figure(figsize=(10, 6))`
2. `sns.histplot(df['skor_investasi'], bins=20, kde=True)`
3. `plt.title('Distribusi Skor Investasi')`
4. `plt.xlabel('Jumlah Skor_Investasi')`
5. `plt.ylabel('Frekuensi')`
6. `plt.show()`




Gambar 20 Distribusi Skor Investasi

Dari visualisasi histogram di atas menunjukkan persebaran yang cukup merata di seluruh rentang nilai dari 1 hingga 10, tanpa adanya dominasi yang signifikan pada skor tertentu. Hal ini mengindikasikan bahwa proyek energi terbarukan yang dianalisis memiliki tingkat kelayakan investasi yang cukup beragam dan tersebar secara seimbang. Selain itu, tidak terlihat adanya kemiringan distribusi yang condong ke kiri maupun kanan yang mencoloknya ke arah skor rendah maupun tinggi, yang berarti data tersebut tidak memiliki nilai ekstrem yang sangat tinggi.

- Relationship

Tabel 3.2.2 22 Kode Relasi Setaip Variabel Numerik

```
1. plt.figure(figsize=(8, 6))
2. sns.heatmap(data=df[['kapasitas_terpasang_mw', 'produksi_energi_gwh',
   'populasi_terlayani', 'emisi_karbon_terpangkas', 'laju_efisiensi',
   'skor_investasi']].corr(),
   i. annot=True,
   ii. cmap='viridis',
   iii. fmt='.2f')
3. plt.title('Relasi Dari Setiap Kolom Numerik')
4. plt.show()
```



Dari hasil visualisasi heatmap di atas dapat diketahui bahwa hampir seluruh hubungan antar variabel memiliki nilai korelasi yang sangat rendah karena mendekati 0, baik positif maupun negatif. Hal ini menunjukkan bahwa tidak terdapat hubungan linear yang kuat antara variabel-variabel seperti kapasitas terpasang, produksi energi, populasi terlayani, emisi karbon terpasang, laju efisiensi, dan skor investasi.

Hubungan antara kapasitas terpasang dengan produksi energi yang seharusnya secara logika berkorelasi justru menunjukkan nilai yang sangat kecil sekitar -0.03, yang mengindikasikan bahwa peningkatan kapasitas tidak selalu diikuti oleh peningkatan produksi secara signifikan. Hal ini bisa menjadi indikasi adanya faktor lain seperti efisiensi operasional atau kondisi fasilitas yang mempengaruhi hasil produksi. Selain itu, variabel seperti laju efisiensi dan skor investasi juga



tidak menunjukkan hubungan kuat dengan variabel lain, yang berarti penilaian investasi dan efisiensi tidak secara langsung dipengaruhi oleh besaran kapasitas atau produksi.

3.2.3 Data Preparation

a) Inconsistent Values

Tabel 3.2.3. 1 Kode Ubah Tipe Data Menjadi Datetime

- | |
|--|
| <pre>1. #Penanganan tipe data pada kolom tanggal_laporan 2. df["tanggal_laporan"] = pd.to_datetime(df["tanggal_laporan"], format="mixed") #Mengubah tipe data ke datetime</pre> |
|--|

Kode tersebut digunakan untuk mengubah kolom tanggal_laporan menjadi tipe data datetime meskipun format tanggalnya beragam, kemudian menampilkan lima data pertama dari kolom tersebut untuk memastikan bahwa proses konversi telah berhasil dan data sudah dalam format yang benar untuk analisis berbasis waktu.

Tabel 3.2.3. 2 Kode Ubah Tipe Data Menjadi Int

- | |
|---|
| <pre>1. #Penanganan tipe data pada kolom tahun 2. df['tahun'] = df['tahun'].astype('Int64')</pre> |
|---|

Kode tersebut digunakan untuk mengubah tipe data pada kolom tahun menjadi tipe integer yang bersifat nullable Int, agar data kolom tahun sifatnya bilangan bulat karena tidak relevan jika angka tahun mengandung desimal atau koma.

Tabel 3.2.3. 3 Kode Menghapus Kata “IDR”

- | |
|--|
| <pre>1. #Menghapus kata 'IDR' 2. df['biaya_operasional'] = df['biaya_operasional'].str.replace('IDR', '', regex=False)</pre> |
|--|

Kode tersebut digunakan untuk menghapus teks “IDR” dari setiap nilai pada kolom biaya_operasional, sehingga data yang semula berbentuk string dengan format mata uang menjadi lebih bersih dan siap untuk diproses lebih lanjut, misalnya dikonversi menjadi tipe numerik.

Tabel 3.2.3. 4 Kode Mengubah Variabel Ke Numerik

- | |
|---|
| <pre>1. #Mengubah kolom biaya_operasional ke numeric 2. df['biaya_operasional'] = pd.to_numeric(df['biaya_operasional'], errors='coerce')</pre> |
|---|



Kode tersebut digunakan untuk mengonversi nilai pada kolom biaya_operasional menjadi tipe data numerik, jadi data tersebut isi nya berupa angka bilangan bulat.

Tabel 3.2.3. 5 Kode Ubah Tipe Data Ke Float

1. #mengubah tipe data kolom biaya_operasional
2. `df['biaya_operasional'] = df['biaya_operasional'].astype('Float64')`

Kode tersebut digunakan untuk mengubah tipe data kolom biaya_operasional menjadi tipe Float64, sehingga nilai dalam kolom dapat berupa angka desimal.

Tabel 3.2.3. 6 Kode Membuat Huruf Besar Awal Kata

1. #Mengubah Format Format Penulisan Menjadi Kapital Pada Awal Kata
2. `df['wilayah'] = df['wilayah'].str.capitalize()`
3. `print(df['wilayah'].unique())`

```
['Bali' nan 'Sumatra' 'Nusa tenggara' 'Sulawesi' 'Papua' 'Jawa' 'Java'  
'Kalimantan']
```

Gambar 22 Perbaikan Huruf Kapital Depan Kata

Kode tersebut digunakan untuk merapikan format penulisan pada kolom wilayah dengan mengubah setiap nilai menjadi huruf kapital di awal kata, sehingga data menjadi lebih konsisten, kemudian menampilkan seluruh nilai unik pada kolom tersebut untuk memeriksa hasil perubahan dan memastikan tidak ada perbedaan penulisan yang tersisa.

Tabel 3.2.3. 7 Kode Mapping Kolom Wilayah

1. `df['wilayah'] = df['wilayah'].replace({`
2. `'Sumtra': 'Sumatera',`
3. `'Java': 'Jawa',`
4. `})`
5. `for col in ['wilayah']:`
6. `print(df[col].unique())`



```
['Bali' nan 'Sumatra' 'Nusa Tenggara' 'Sulawesi' 'Papua' 'Jawa'  
'Kalimantan']
```

Gambar 23 Kolom Wilayah Setelah Ditangani

Kode tersebut digunakan untuk memperbaiki dan menstandarkan penulisan pada kolom wilayah, yaitu dengan mengganti nilai yang tidak tepat seperti “Sumtra” menjadi “Sumatera” dan “Java” menjadi “Jawa”, kemudian menampilkan seluruh nilai unik pada kolom tersebut untuk memastikan bahwa proses perbaikan data telah berhasil dan tidak ada lagi penulisan yang tidak konsisten.

Berdasarkan Output di atas dapat disimpulkan bahwa inconsistensi sudah di atasi dari memperbaiki huruf kapital yang tidak konsisten dengan yang lain, lalu memperbaiki inputan data yang salah seperti "Sumtra" di ubah menjadi "Sumatra" dan "Java" di ubah menjadi "Jawa". Dengan begitu proses analisis dan visualisasi untuk kedepannya bisa lebih mudah.

Tabel 3.2.3. 8 Kode Mapping Kolom Jenis Energi

```
1. df['jenis_energi'] = df['jenis_energi'].replace({  
2. 'Hydro Power': 'Hydro',  
3. 'S_Energy': 'Solar',  
4. })  
  
5. for col in ['jenis_energi']:  
6. print(df[col].unique())
```

```
*** ['Hydro' 'Geothermal' nan 'Solar' 'Wind']
```

Gambar 24 Kolom Jenis Energi Setelah Ditangani

Kode tersebut digunakan untuk mengganti nilai yang tidak konsisten pada kolom jenis_energi menjadi lebih seragam, seperti mengubah “Hydro Power” menjadi “Hydro” dan “S_Energy” menjadi “Solar”, kemudian menampilkan seluruh nilai unik pada kolom tersebut untuk memastikan bahwa proses pembersihan data telah berhasil.



Berdasarkan Output di atas dapat di simpulkan inconsistensi pada kolom jenis_energi sudah berhasil di perbaiki dengan mengganti inputan data "S_Energy" di ubah menjadi "Solar" karena dalam satu konteks dan data "Hydro Power" menjadi "Hydro" karena masih dalam satu konteks. Dengan begitu data menjadi lebih bersih dan tidak ada lagi inputan data yang salah.

b) Missing Values

Tabel 3.2.3. 9 Kode Metode Modus Kolom Wilayah

1. <code>df['wilayah'] = df['wilayah'].fillna(df['wilayah'].dropna().mode()[0])</code>
--

Kode diatas bertujuan untuk mengimputasi kolom wilayah yang memiliki sekitar 5% missing value, penggunaan metode modus (nilai yang paling sering muncul) merupakan pilihan yang tepat dan cukup aman. Hal ini dikarenakan proporsi data yang hilang relatif kecil, sehingga pengisian dengan nilai dominan tidak akan memberikan distorsi yang signifikan terhadap distribusi data secara keseluruhan.

Insight yang dapat diambil adalah bahwa dengan mengisi nilai yang hilang menggunakan wilayah yang paling sering muncul, dataset menjadi lebih lengkap dan siap digunakan untuk analisis lanjutan tanpa kehilangan banyak informasi. Namun, pendekatan ini juga memiliki konsekuensi, yaitu berpotensi sedikit meningkatkan dominasi wilayah tertentu dalam dataset. Meskipun demikian, karena persentase missing value yang rendah, dampak bias tersebut cenderung minimal dan masih dapat diterima. Secara keseluruhan, imputasi pada kolom wilayah membantu menjaga keseimbangan antara kelengkapan data dan kualitas analisis, tanpa perlu menghapus baris data yang sebenarnya masih memiliki informasi penting pada kolom lainnya.

Tabel 3.2.3. 10 Kode Metode Modus Kolom Target Tercapai

1. <code>df['target_tercapai'] = df['target_tercapai'].fillna(df['target_tercapai'].dropna().mode()[0])</code>
--

Kode diatas bertujuan untuk mengimputasi kolom target_tercapai yang memiliki persentase missing value sangat kecil (sekitar 1%), penggunaan metode modus (nilai yang paling sering muncul, yaitu “Yes” atau “No”) merupakan pendekatan yang tepat dan minim risiko. Karena jumlah data yang hilang sangat sedikit, pengisian nilai tersebut tidak akan memberikan



dampak signifikan terhadap distribusi keseluruhan maupun hasil analisis. Insight yang dapat diambil adalah bahwa imputasi ini membantu menjaga kelengkapan data tanpa perlu menghapus baris yang sebenarnya masih memiliki informasi penting pada kolom lain. Selain itu, karena `target_tercapai` merupakan variabel kategorikal/biner, penggunaan modus juga mempertahankan konsistensi logika data tanpa menambahkan nilai baru yang tidak relevan.

Namun, perlu diperhatikan bahwa imputasi dengan modus dapat sedikit memperkuat dominasi kategori tertentu (misalnya “Yes” jika itu yang paling sering muncul). Meskipun demikian, karena proporsi missing sangat kecil, potensi bias yang dihasilkan cenderung tidak signifikan dan masih dapat diterima. Secara keseluruhan, imputasi pada kolom ini merupakan langkah yang efisien dan tepat untuk memastikan dataset siap digunakan dalam analisis lanjutan.

Tabel 3.2.3. 11 Kode Metode Median Kolom Populasi Terlayani

1. <code>df['populasi_terlayani'].fillna(df['populasi_terlayani'].median(), inplace=True)</code>
--

Kode diatas bertujuan untuk menangani kolom `populasi_terlayani` yang memiliki sekitar 17% data hilang, penggunaan metode median merupakan pilihan yang tepat dan cukup aman. Hal ini karena kolom ini bersifat numerik dan kemungkinan memiliki distribusi yang tidak simetris atau mengandung outlier, sehingga median lebih representatif dibandingkan rata-rata (mean). Insight yang dapat diambil adalah bahwa imputasi dengan median membantu menjaga kestabilan distribusi data tanpa terlalu terpengaruh oleh nilai ekstrem. Dengan demikian, nilai populasi yang dihasilkan tetap mencerminkan kondisi mayoritas data. Selain itu, langkah ini juga memungkinkan dataset tetap utuh tanpa perlu menghapus baris yang memiliki informasi penting pada kolom lain.

Namun, perlu diperhatikan bahwa dengan proporsi missing value yang cukup besar (mendekati 20%), hasil imputasi dapat mengurangi variasi data dan berpotensi membuat nilai populasi terlihat lebih “seragam” di sekitar nilai tengah. Meskipun demikian, pendekatan ini masih dianggap sebagai kompromi terbaik antara menjaga kelengkapan data dan mempertahankan kualitas analisis. Secara keseluruhan, imputasi pada kolom `populasi_terlayani` memungkinkan analisis tetap berjalan dengan baik, namun hasilnya perlu diinterpretasikan dengan mempertimbangkan adanya proses pengisian nilai tersebut.



Tabel 3.2.3. 12 Kode Metode Median Kolom Emisi Karbon

```
1. df['emisi_karbon_terpangkas'].fillna(df['emisi_karbon_terpangkas'].median(),  
    inplace=True)
```

Kode diatas bertujuan untuk menangani kolom emisi_karbon_terpangkas yang memiliki sekitar 11–12% data hilang, penggunaan metode median merupakan pendekatan yang tepat. Hal ini dikarenakan data emisi karbon umumnya memiliki potensi outlier atau nilai ekstrem, sehingga median lebih stabil dan tidak mudah terpengaruh oleh nilai yang terlalu tinggi atau rendah dibandingkan dengan rata-rata (mean). Insight yang dapat diambil adalah bahwa imputasi dengan median membantu menjaga representasi nilai tengah dari data emisi karbon yang terpangkas, sehingga distribusi data tetap relatif terjaga. Selain itu, langkah ini memungkinkan dataset tetap lengkap tanpa perlu menghapus baris yang mungkin masih memiliki informasi penting pada kolom lainnya, seperti produksi energi atau efisiensi.

Namun demikian, karena proporsi missing value cukup signifikan, proses imputasi ini dapat mengurangi variasi alami dalam data dan membuat beberapa nilai menjadi lebih terpusat di sekitar median. Hal ini berpotensi mengurangi sensitivitas analisis terhadap variasi sebenarnya di lapangan, terutama jika digunakan untuk analisis yang mendalam atau pemodelan. Secara keseluruhan, imputasi pada kolom emisi_karbon_terpangkas merupakan solusi yang seimbang antara menjaga kelengkapan data dan mempertahankan kualitas analisis, dengan catatan bahwa interpretasi hasil tetap perlu mempertimbangkan adanya proses pengisian nilai tersebut.

Tabel 3.2.3. 13 Kode Metode Median Kolom Laju Efisiensi

```
1. df['laju_efisiensi'].fillna(df['laju_efisiensi'].median(), inplace=True)
```

Kode diatas bertujuan untuk menangani kolom laju_efisiensi yang memiliki sekitar 11–12% missing value. Penggunaan metode median untuk imputasi merupakan pilihan yang sesuai, karena nilai efisiensi sering kali memiliki variasi yang cukup besar dan berpotensi mengandung outlier. Dengan median, nilai yang dihasilkan lebih stabil dan tidak mudah terpengaruh oleh nilai ekstrem.

Insight yang dapat diambil adalah bahwa imputasi ini membantu menjaga kelengkapan data sehingga kolom laju_efisiensi tetap dapat digunakan dalam analisis tanpa harus menghapus



banyak baris data. Selain itu, penggunaan median juga mempertahankan representasi nilai tengah dari distribusi efisiensi, sehingga hasil analisis masih mencerminkan kondisi umum yang terjadi.

Namun, dengan adanya proporsi missing yang cukup signifikan, proses imputasi dapat mengurangi variasi data dan membuat nilai efisiensi menjadi lebih terpusat di sekitar median. Hal ini berpotensi mengurangi sensitivitas dalam mendeteksi perbedaan efisiensi antar entitas. Oleh karena itu, meskipun data sudah siap digunakan, hasil analisis tetap perlu diinterpretasikan dengan mempertimbangkan adanya proses imputasi tersebut.

Tabel 3.2.3. 14 Kode Metode Median Kolom Skor Investasi

1. <code>df['skor_investasi'].fillna(df['skor_investasi'].median(), inplace=True)</code>
--

Kode diatas bertujuan untuk menangani kolom skor_investasi yang memiliki sekitar 12% missing value, sehingga perlu dilakukan penanganan agar data tetap dapat digunakan secara optimal. Penggunaan metode median sebagai imputasi merupakan pilihan yang tepat, karena nilai skor cenderung bersifat numerik dan dapat memiliki variasi yang cukup besar, termasuk kemungkinan adanya nilai ekstrem. Median mampu memberikan representasi nilai tengah yang lebih stabil dibandingkan rata-rata (mean).

Insight yang dapat diambil adalah bahwa imputasi ini membantu menjaga kelengkapan dataset tanpa harus menghapus baris data yang masih memiliki informasi penting pada kolom lainnya. Dengan demikian, analisis terkait performa investasi atau efisiensi tetap dapat dilakukan secara menyeluruh. Selain itu, penggunaan median juga menjaga distribusi data agar tidak terlalu terpengaruh oleh nilai yang tidak wajar.

Namun demikian, karena proporsi missing value cukup signifikan, proses imputasi dapat menyebabkan penurunan variasi data dan membuat nilai skor cenderung berkumpul di sekitar nilai tengah. Hal ini berpotensi mengurangi kemampuan analisis dalam membedakan performa antar entitas secara lebih detail. Oleh karena itu, hasil analisis tetap perlu diinterpretasikan dengan mempertimbangkan adanya proses imputasi tersebut.

Tabel 3.2.3. 15 Kode Mengisi “Unknown” Kolom Tipe Provider

1. <code>df['tipe_provider'].fillna('Unknown', inplace=True)</code>

Kode diatas bertujuan untuk menangani kolom tipe_provider penanganan ini dilakukan dengan mengisi nilai kosong menggunakan kategori “Unknown”. Hal ini merupakan langkah yang



tepat untuk menjaga kelengkapan data tanpa menghilangkan informasi penting. Dengan pendekatan ini, data yang sebelumnya kosong tetap dipertahankan dalam dataset, sehingga jumlah baris tidak berkurang dan analisis tetap mencerminkan keseluruhan kondisi data. Selain itu, penggunaan label “Unknown” juga membantu dalam proses analisis kategorikal, karena memungkinkan kita untuk mengidentifikasi dan memisahkan data yang memang tidak memiliki informasi provider secara jelas.

Tabel 3.2.3. 16 Kode Metode Modus Kolom Status Operasional

```
1. df['status_operasional'].fillna(df['status_operasional'].mode()[0], inplace=True)
```

Kode diatas bertujuan untuk mwnangani missing value pada kolom status operasional dengan mengisi menggunakan nilai modus (nilai yang paling sering muncul) merupakan pendekatan yang efektif untuk menjaga konsistensi distribusi data. Dengan cara ini, data yang kosong diasumsikan memiliki karakteristik yang sama dengan mayoritas data, sehingga tidak mengganggu pola umum dalam dataset. Insight yang dapat diperoleh adalah bahwa sebagian besar unit kemungkinan berada dalam kondisi operasional yang dominan (misalnya Active), sehingga pengisian dengan modus masih relevan secara konteks. Selain itu, pendekatan ini membantu menghindari pengurangan jumlah data sekaligus mempertahankan kualitas analisis, terutama ketika kolom ini digunakan untuk melihat performa berdasarkan status operasional.

Tabel 3.2.3. 17 Kode Mengisi “Unknown” Kolom Jenis Energi

```
1. df['jenis_energi'].fillna('Unknown', inplace=True)
```

Kolom jenis_energi memiliki sekitar 20% missing value, sehingga penanganannya perlu dilakukan dengan hati-hati karena proporsinya cukup besar. Jika missing value diisi menggunakan label seperti “Unknown”, maka pendekatan ini dinilai lebih aman dibandingkan menggunakan modus. Hal ini karena penggunaan modus berpotensi memperbesar dominasi satu jenis energi tertentu dan dapat menimbulkan bias yang signifikan dalam distribusi data. Insight yang dapat diambil adalah bahwa dengan menambahkan kategori “Unknown”, kita tetap mempertahankan seluruh data tanpa harus menghapus baris yang memiliki informasi penting pada kolom lain. Selain



itu, pendekatan ini juga menjaga kejujuran data, karena kita tidak memaksakan asumsi terhadap jenis energi yang sebenarnya tidak diketahui.

Namun, keberadaan kategori “Unknown” juga perlu diperhatikan dalam analisis, karena jumlahnya yang cukup besar dapat mempengaruhi interpretasi distribusi jenis energi secara keseluruhan. Dalam beberapa kasus, data dengan label ini mungkin perlu dipisahkan atau dianalisis secara khusus agar tidak mengganggu insight utama. Secara keseluruhan, penanganan missing value pada kolom jenis_energi dengan menambahkan kategori baru merupakan strategi yang tepat untuk menjaga keseimbangan antara kelengkapan data dan akurasi analisis, terutama ketika tingkat kehilangan data cukup tinggi.

Tabel 3.2.3. 18 Kode Cek Missing Values

1. `pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])`

*** Null Ratio in %	
tanggal_laporan	0.0
tahun	0.0
wilayah	0.0
jenis_energi	0.0
tipe_provider	0.0
status_operasional	0.0
kapasitas_terpasang_mw	0.0
produksi_energi_gwh	0.0
populasi_terlayani	0.0
biaya_operasional	0.0
emisi_karbon_terpangkas	0.0
laju_efisiensi	0.0
skor_investasi	0.0
target_tercapai	0.0

Gambar 25 Missing Values(Setelah Dibersihkan)

Berdasarkan output di atas, terlihat bahwa seluruh kolom sudah memiliki nilai Null Ratio sebesar 0%, yang berarti tidak terdapat missing values dalam dataset. Hal ini menunjukkan bahwa proses data cleaning telah berhasil dilakukan dengan baik, sehingga data sudah lengkap dan siap digunakan untuk analisis lebih lanjut tanpa risiko bias akibat data yang hilang.



c) Duplicated Values

Tabel 3.2.3. 19 Kode Menghapus Baris Duplikat

```
1. df = df.drop_duplicates()
```

Kode diatas adalah untuk menghapus data ter-duplikasi, kualitas data menjadi lebih baik karena tidak ada lagi pencatatan yang berulang. Hal ini akan meningkatkan akurasi analisis, terutama pada perhitungan seperti total, rata-rata, maupun distribusi, yang sebelumnya bisa terdistorsi akibat data yang dihitung lebih dari satu kali.

Selain itu, proses ini juga membantu menghindari bias dalam analisis, karena data duplikat dapat memberikan bobot lebih besar pada observasi tertentu secara tidak wajar. Dengan dataset yang sudah bersih dari duplikasi, hasil analisis menjadi lebih representatif terhadap kondisi sebenarnya.

Tabel 3.2.3. 20 Kode Cek Duplicated Values

```
1. df[df.duplicated()]
```

*** tanggal_laporan tahun wilayah jenis_energi tipe_provider status_operasional kapasitas_terpasang_mw produksi_energi_gwh populasi_terlayani biaya_operasional emisi_karbon_terpangkas laju_efisiensi skor_investasi target_tercapai

Gambar 26 Duplicated Values(Setelah Dibersihkan)

Berdasarkan output yang ditampilkan, dapat disimpulkan bahwa seluruh data yang mengalami duplikasi telah berhasil ditangani dengan cara menghapus baris yang memiliki nilai duplikat. Proses ini penting untuk memastikan bahwa setiap data bersifat unik dan tidak terjadi perhitungan ganda yang dapat memengaruhi hasil analisis. Dengan menghilangkan data duplikat, kualitas dataset menjadi lebih bersih, konsisten, dan valid, sehingga dapat meningkatkan akurasi serta mempermudah proses analisis pada tahap selanjutnya.

d) Outliers Values

Tabel 3.2.3. 21 Kode Penanganan IQR Kolom Populasi Terlayani

```
1. columns_to_impute = ["populasi_terlayani"]  
  
2. for col in columns_to_impute:  
3. Q1 = df[col].quantile(0.25)
```



```
4. Q3 = df[col].quantile(0.75)
5. IQR = Q3 - Q1
6. lower_bound = Q1 - 1.5 * IQR
7. upper_bound = Q3 + 1.5 * IQR

8. # Menggunakan .loc[] agar tidak muncul SettingWithCopyWarning
9. df.loc[:, col] = df[col].clip(lower=lower_bound, upper=upper_bound)
```

Kode tersebut digunakan untuk menangani outlier pada kolom populasi_terlayani dengan metode IQR, yaitu dengan menghitung kuartil pertama dan ketiga, menentukan batas bawah dan atas, lalu menyesuaikan semua nilai yang berada di luar batas tersebut agar tetap berada dalam rentang wajar, sehingga distribusi data menjadi lebih stabil dan siap untuk dianalisis.

Tabel 3.2.3. 22 Kode Cek Outlier Values

```
1. results = []

2. cols = df.select_dtypes(include=['float64', 'int64'])

3. for col in cols:
4.     q1 = df[col].quantile(0.25)
5.     q3 = df[col].quantile(0.75)
6.     iqr = q3 - q1
7.     lower_bound = q1 - 1.5*iqr
8.     upper_bound = q3 + 1.5*iqr
9.     outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
10.    percent_outliers = (len(outliers)/len(df))*100
11.    results.append({'laju_efisiensi': col, 'Persentase Outliers': percent_outliers})

12. # Dataframe dari list hasil
13. results_df = pd.DataFrame(results)
```



```
14. results_df.set_index('laju_efisiensi', inplace=True)
15. results_df = results_df.rename_axis(None, axis=0).rename_axis('kolom', axis=1)

16. # Tampilkan dataframe
17. display(results_df)
```

	kolom Persentase Outliers
tahun	0.000000
kapasitas_terpasang_mw	0.391773
produksi_energi_gwh	0.000000
populasi_terlayani	0.000000
biaya_operasional	0.000000
emisi_karbon_terpangkas	0.000000
laju_efisiensi	0.979432
skor_investasi	0.000000

Gambar 27 Outliers Setelah Ditangani

Berdasarkan output yang di tampilkan, dapat diketahui kolom outliers yang di tangani hanyalah kolom populasi_terlayani sedangkan kolom kapasitas_terpasang_mw dan kolom laju_efisiensi tidak perlu dan di biarkan saja.

Outliers pada kolom populasi_terlayani harus di tangani karena terdapat nilai yang tidak masuk akal, seperti nilai negatif. Secara logika, jumlah populasi tidak mungkin bernilai kurang dari nol, sehingga kemunculan nilai tersebut menunjukkan adanya kesalahan data, baik dari proses pencatatan maupun pengolahan. Jika outliers seperti ini dibiarkan, maka dapat menyebabkan hasil analisis menjadi bias dan tidak akurat, misalnya dalam menghitung rata-rata atau melihat distribusi data. Setelah proses tersebut, nilai-nilai yang sebelumnya tidak logis, seperti nilai negatif, telah berhasil dihilangkan atau diperbaiki sehingga data menjadi lebih valid dan sesuai dengan kondisi nyata. Dengan tidak adanya nilai yang menyimpang secara ekstrem dan tidak masuk akal, distribusi data pada kolom ini menjadi lebih stabil dan representatif.

Outliers pada kolom kapasitas_terpasang_mw tidak perlu di tangani secara khusus karena nilai-nilai ekstrem yang muncul masih dapat dianggap wajar dalam konteks data energi. Secara alami, kapasitas pembangkit listrik memang memiliki rentang yang sangat bervariasi, mulai dari skala kecil hingga skala besar tergantung pada jenis pembangkit, teknologi yang digunakan, serta



wilayah operasionalnya. Oleh karena itu, nilai yang terlihat jauh lebih tinggi dibandingkan mayoritas data bukan berarti kesalahan, melainkan bisa merepresentasikan pembangkit dengan kapasitas besar.

Outliers pada kolom laju_efisiensi juga tidak perlu di tangani secara khusus karena karena variasi nilai yang muncul masih tergolong wajar dan dapat dijelaskan secara kontekstual. Laju efisiensi dalam sektor energi sangat dipengaruhi oleh berbagai faktor, seperti jenis sumber energi yang digunakan, teknologi pembangkit, serta kondisi operasional di lapangan. Perbedaan efisiensi antar pembangkit merupakan hal yang umum, sehingga nilai yang lebih tinggi atau lebih rendah dari mayoritas data belum tentu menunjukkan kesalahan. Selama tidak terdapat nilai yang tidak logis, seperti efisiensi bernilai negatif atau melebihi batas wajar, misalnya di atas 100% jika dalam bentuk persentase, maka data tersebut masih dapat dianggap valid. Oleh karena itu, mempertahankan outliers pada kolom laju efisiensi justru penting agar analisis tetap mencerminkan kondisi nyata dan keberagaman performa antar pembangkit energi.

3.2.4 Construct Data

Pada tahap Construct Data, tidak diperlukan adanya penambahan atau pembentukan variabel baru dalam dataset ini, karena seluruh kolom yang tersedia sudah cukup representatif dan mendukung kebutuhan proses analisis. Struktur data yang ada telah mampu menggambarkan informasi yang dibutuhkan secara jelas, sehingga analisis dapat dilakukan secara langsung tanpa perlu melakukan transformasi atau konstruksi fitur tambahan.

3.2.5 Data Reduction

3.2.5. 1 Kode Hapus Kolom

```
1. df = df.drop('tahun', axis=1)
```

Kode tersebut digunakan untuk menghapus kolom tahun dari. Dengan axis=1, perintah ini menandakan bahwa yang dihapus adalah kolom, bukan baris. Setelah dijalankan, DataFrame df tidak lagi memiliki kolom tahun.



3.2.5. 2 Kode Cek Kolom

1. df.columns

```
*** Index(['tanggal_laporan', 'wilayah', 'jenis_energi', 'tipe_provider',  
         'status_operasional', 'kapasitas_terpasang_mw', 'produksi_energi_gwh',  
         'populasi_terlayani', 'biaya_operasional', 'emisi_karbon_terpangkas',  
         'laju_efisiensi', 'skor_investasi', 'target_tercapai'],  
         dtype='object')
```

Gambar 28 Tampilan Kolom


Pada tahap ini dilakukan proses data reduction dengan menghapus kolom tahun karena dinilai tidak lagi relevan untuk analisis. Hal ini disebabkan informasi tahun sudah secara implisit tercakup dalam kolom tanggal_laporan, sehingga keberadaan kolom tahun menjadi redundan dan berpotensi menimbulkan duplikasi informasi. Dengan menghapus kolom yang tidak diperlukan, struktur dataset menjadi lebih ringkas dan terorganisir, serta membantu meningkatkan efisiensi dalam proses pengolahan dan analisis data selanjutnya.

3.2.6 Data Graph

Visualisasi dan dashboard dibuat menggunakan Tableau untuk menjawab seluruh pertanyaan bisnis yang telah ditetapkan. Berikut adalah hasil visualisasi dan jawaban atas setiap pertanyaan bisnis:

1. Distribusi Kapasitas Pada Setiap Wilayah

Berdasarkan visualisasi yang ditampilkan pada Gambar 29, dapat dilihat bagaimana distribusi kapasitas terpasang (MW) pada seluruh wilayah proyek di Indonesia. Grafik tersebut memberikan gambaran perbandingan kapasitas antar wilayah, sehingga memudahkan dalam mengidentifikasi wilayah dengan kapasitas tertinggi maupun terendah.



Gambar 29 Distribusi Terpasang Setiap Wilayah


Berdasarkan visualisasi tersebut, distribusi kapasitas terpasang di seluruh wilayah menunjukkan adanya perbedaan yang cukup jelas antar daerah. Wilayah Jawa memiliki kapasitas terpasang paling tinggi, jauh melampaui wilayah lainnya, diikuti oleh Sumatra dan Nusa Tenggara. Sementara itu, wilayah seperti Kalimantan, Papua, dan Sulawesi memiliki kapasitas yang relatif lebih rendah.

Jika dilihat dari persebarannya, terdapat kecenderungan dominasi pada rentang kapasitas menengah hingga tinggi (sekitar 500 ribu hingga di atas 800 ribu MW), terutama pada wilayah dengan perkembangan infrastruktur energi yang lebih maju. Namun, dominasi paling mencolok berada pada Jawa sebagai outlier dengan kapasitas tertinggi. Hal ini menunjukkan bahwa pembangunan dan pemanfaatan energi masih terpusat di wilayah tertentu, sehingga mengindikasikan adanya ketimpangan distribusi kapasitas energi antar wilayah di Indonesia.

2. Proporsi Jenis Energi

Berdasarkan visualisasi pada Gambar 30, ditampilkan proporsi kontribusi masing-masing jenis energi terhadap keseluruhan pemanfaatan energi pada dataset yang dianalisis. Grafik ini memberikan gambaran mengenai perbandingan kontribusi antar jenis energi yang digunakan.

Proporsi Kontribusi Setiap Jenis Energi




Gambar 30 Proporsi Jenis Energi

Dari visualisasi tersebut, terlihat bahwa kontribusi energi relatif cukup seimbang antar jenis energi, dengan Hydro dan Solar menjadi jenis energi yang memiliki proporsi terbesar, masing-masing sebesar 22%. Sementara itu, Geothermal dan Wind memiliki kontribusi yang sedikit lebih rendah, yaitu masing-masing sebesar 18%. Selain itu, terdapat kategori *Unknown* sebesar 20%, yang menunjukkan masih adanya data yang belum terklasifikasi dengan jelas.

Secara keseluruhan, tidak terdapat dominasi yang sangat signifikan dari satu jenis energi tertentu, sehingga dapat disimpulkan bahwa pemanfaatan energi terbarukan dalam dataset ini sudah cukup beragam. Namun, keberadaan kategori *Unknown* yang cukup besar mengindikasikan perlunya perbaikan kualitas data agar analisis yang dihasilkan dapat lebih akurat dan representatif.

3. Tren Produksi Energi Dari Bulan Ke Bulan

Berdasarkan visualisasi pada Gambar 31, ditampilkan tren produksi energi bulanan selama periode pengamatan. Grafik ini menunjukkan bagaimana perubahan jumlah produksi energi dari waktu ke waktu serta membantu mengidentifikasi pola kenaikan dan penurunan yang terjadi.



Gambar 31 Tren Produksi Dari Waktu Ke Waktu


Dari grafik tersebut, terlihat bahwa produksi energi cenderung fluktuatif dari waktu ke waktu, tanpa pola peningkatan atau penurunan yang konsisten. Sebagian besar nilai produksi berada pada kisaran 270 ribu hingga 320 ribu GWh, yang menunjukkan adanya stabilitas relatif dalam rentang tertentu.

Namun, terdapat beberapa titik yang menonjol, seperti puncak produksi tertinggi sekitar 371 ribu GWh, yang menunjukkan periode dengan performa produksi yang sangat baik. Di sisi lain, terdapat penurunan signifikan di akhir periode hingga sekitar 136 ribu GWh, yang merupakan nilai terendah dan jauh di bawah rata-rata sebelumnya.

Penurunan drastis ini dapat mengindikasikan adanya gangguan operasional, faktor musiman, atau kemungkinan data yang belum lengkap. Secara keseluruhan, meskipun produksi energi relatif stabil pada periode tertentu, fluktuasi yang terjadi menunjukkan perlunya evaluasi lebih lanjut untuk menjaga konsistensi produksi energi.

4. Hubungan Antara Kapasitas Terpasang Dan Produksi Energi

Berdasarkan visualisasi pada Gambar 32, ditampilkan hubungan antara kapasitas terpasang (MW) dengan produksi energi (GWh) pada masing-masing wilayah. Grafik ini bertujuan untuk melihat sejauh mana kapasitas yang dimiliki berpengaruh terhadap realisasi produksi energi.



Gambar 32 Hubungan Antara Kapasitas Dan Produksi Energi Setiap Wilayah


Dari visualisasi tersebut, terlihat adanya hubungan positif antara kapasitas terpasang dan produksi energi, di mana wilayah dengan kapasitas yang lebih besar cenderung menghasilkan produksi energi yang lebih tinggi. Hal ini menunjukkan bahwa secara umum, kapasitas yang dimiliki telah dimanfaatkan dengan cukup baik. Wilayah Jawa terlihat menonjol dengan kapasitas dan produksi yang paling tinggi dibandingkan wilayah lainnya, sehingga menjadi pusat utama produksi energi. Sementara itu, wilayah seperti Sumatra dan Nusa Tenggara juga menunjukkan performa yang cukup baik dengan kapasitas dan produksi yang relatif seimbang.

Namun, terdapat beberapa wilayah seperti Kalimantan dan Papua yang memiliki kapasitas cukup rendah dengan produksi yang juga lebih kecil, yang mengindikasikan keterbatasan infrastruktur atau pemanfaatan energi di wilayah tersebut. Secara keseluruhan, tidak terlihat adanya anomali signifikan seperti kapasitas tinggi namun produksi rendah. Hal ini menunjukkan bahwa sebagian besar wilayah telah memanfaatkan kapasitasnya secara cukup optimal, meskipun masih terdapat perbedaan performa antar wilayah yang perlu diperhatikan.



5. Proporsi Status Operasional

Berdasarkan visualisasi pada Gambar 33, ditampilkan persentase status operasional fasilitas energi yang terdiri dari kondisi aktif, maintenance, dan rusak. Grafik ini memberikan gambaran mengenai kondisi operasional fasilitas secara keseluruhan.



Gambar 33 Proporsi Status Operasional


Dari visualisasi tersebut, terlihat bahwa sekitar 40% fasilitas berada dalam kondisi aktif, yang menunjukkan bahwa sebagian besar fasilitas masih beroperasi dengan baik. Namun, terdapat 30% fasilitas dalam kondisi maintenance dan 30% dalam kondisi rusak, yang menunjukkan bahwa sekitar 60% fasilitas tidak berada dalam kondisi optimal.

Proporsi ini mengindikasikan bahwa masih terdapat tantangan besar dalam menjaga keandalan operasional fasilitas energi. Tingginya persentase fasilitas yang tidak aktif dapat berdampak pada penurunan produksi energi dan efisiensi operasional secara keseluruhan. Oleh karena itu, diperlukan perhatian lebih dalam hal perawatan dan perbaikan fasilitas agar kinerja operasional dapat ditingkatkan dan lebih banyak fasilitas dapat beroperasi secara optimal.

6. Perbandingan Jumlah Proyek Yang Mencapai Target Berdasarkan Tipe Provider

Berdasarkan visualisasi pada Gambar 34, ditampilkan perbandingan target tercapai berdasarkan tipe provider yang dilihat dari jumlah populasi terlayani pada kategori *Yes* dan *No*.

Grafik ini memberikan gambaran mengenai kontribusi masing-masing provider dalam pencapaian target layanan energi bersih serta membantu mengevaluasi perbedaan performa antar provider.



Gambar 34 Perbandingan Target Tercapai Berdasarkan Tipe Provider

Berdasarkan grafik tersebut, terlihat bahwa provider Unknown memiliki jumlah populasi terlayani tertinggi pada kedua kategori, yaitu sekitar 4.507 pada target tidak tercapai dan 4.505 pada target tercapai. Hal ini menunjukkan bahwa provider ini memiliki cakupan layanan yang paling luas dibanding provider lainnya. Sementara itu, provider Government, Private, dan Foreign NGO memiliki nilai yang relatif berdekatan, berada pada kisaran 2.8 ribu hingga 3.1 ribu.


Kondisi ini belum bisa dikatakan optimal. Disebut merata karena ketiga tipe provider Pemerintah, Swasta, dan Asing memiliki jumlah pencapaian target yang hampir sama. Namun, dari sudut pandang kinerja, yang lebih penting bukan kesetaraan antar provider, melainkan tingkat keberhasilan secara keseluruhan. Jika jumlah proyek yang mencapai target Yes hampir sama dengan yang tidak mencapai target No, itu justru menunjukkan bahwa performa masih belum maksimal. Artinya, sekitar setengah dari proyek masih gagal mencapai target, sehingga efektivitas operasional belum optimal.

Idealnya, jumlah Yes harus jauh lebih tinggi dibandingkan No, sehingga menunjukkan bahwa sebagian besar proyek berhasil. Jadi, meskipun distribusinya merata antar provider, kondisi

ini tetap mengindikasikan bahwa masih diperlukan peningkatan kinerja agar tingkat keberhasilan bisa lebih dominan dibandingkan kegagalan.

7. Perbandingan Jumlah Biaya Operasional Berdasarkan Wilayah

Berdasarkan visualisasi pada Gambar 35, ditampilkan perbandingan jumlah biaya operasional berdasarkan wilayah untuk setiap jenis energi, yaitu *Geothermal*, *Hydro*, *Wind* dan *Solar*. Grafik ini memberikan gambaran mengenai sebaran biaya operasional pada masing-masing wilayah sehingga dapat digunakan untuk melihat wilayah mana yang membutuhkan biaya tertinggi maupun terendah dalam pengelolaan fasilitas energi.



Gambar 35 Biaya Operasional Antar Wilayah


Dari visualisasi tersebut, terlihat bahwa jenis energi Solar dan kategori Unknown cenderung memiliki biaya operasional paling tinggi di hampir seluruh wilayah, dengan puncak tertinggi mencapai kisaran lebih dari 70 miliar, khususnya di wilayah Jawa. Sementara itu, energi Hydro juga menunjukkan biaya yang relatif tinggi namun lebih stabil dibanding Solar. Di sisi lain, Wind dan Geothermal memiliki biaya operasional yang lebih rendah dan cenderung konsisten di berbagai wilayah. Selain itu, terdapat pola bahwa wilayah seperti Jawa dan Kalimantan sering kali



memiliki biaya operasional lebih besar dibanding wilayah lain, yang kemungkinan dipengaruhi oleh skala proyek atau tingkat kebutuhan energi yang lebih tinggi. Secara keseluruhan, distribusi ini mengindikasikan adanya perbedaan signifikan dalam efisiensi dan investasi operasional antar jenis energi dan wilayah.

8. Jumlah Populasi Terlayani Berdasarkan Wilayah

Berdasarkan visualisasi pada Gambar 36, ditampilkan persebaran jumlah populasi terlayani pada setiap wilayah dalam bentuk *treemap*. Grafik ini memberikan gambaran mengenai wilayah mana yang memiliki cakupan layanan energi terbesar dan bagaimana distribusi akses energi bersih tersebar di berbagai wilayah di Indonesia.



Gambar 36 Persebaran Populasi Terlayani Antar Wilayah

Berdasarkan visualisasi tersebut, wilayah Jawa memiliki jumlah populasi terlayani tertinggi, yaitu sekitar 6.764 juta jiwa, jauh lebih besar dibanding wilayah lainnya. Hal ini menunjukkan bahwa akses dan distribusi energi bersih di Jawa sudah menjangkau masyarakat dalam skala yang lebih luas, yang kemungkinan dipengaruhi oleh tingginya jumlah penduduk serta infrastruktur energi yang lebih berkembang.




Sementara itu, wilayah lain seperti Kalimantan sekitar 3.446 juta jiwa , lalu Bali sekitar 3.434 juta jiwa, Papua sekitar 3.417 juta jiwa, dan Sumatra sekitar 3.315 juta jiwa memiliki jumlah populasi terlayani yang relatif berdekatan. Adapun wilayah Nusa Tenggara sekitar 3.273 juta jiwa dan Sulawesi sekitar 3.088 juta jiwa menunjukkan cakupan layanan yang sedikit lebih rendah dibanding wilayah lainnya. Insight penting dari visualisasi ini adalah adanya kesenjangan distribusi layanan energi antar wilayah, di mana Jawa mendominasi secara signifikan. Hal ini dapat menjadi dasar bagi stakeholder untuk memprioritaskan peningkatan akses energi bersih di wilayah dengan cakupan lebih rendah agar pemerataan layanan energi dapat tercapai secara lebih optimal.

3.2.7 Dashboard

A. Dashboard Analisis Kinerja Energi Terbarukan Di Indonesia

Berdasarkan visualisasi pada Gambar dashboard 37, ditampilkan “Analisis Kinerja Energi Terbarukan Di Indonesia” yang mencakup distribusi kapasitas terpasang pada setiap wilayah, hubungan antara kapasitas terpasang dan produksi energi, proporsi kontribusi setiap jenis energi, serta tren produksi energi bulanan. Dashboard ini memberikan gambaran yang komprehensif mengenai performa infrastruktur energi terbarukan sehingga memudahkan stakeholder dalam mengevaluasi kondisi operasional dan mendukung pengambilan keputusan strategis.



Gambar 37 Dashboard Analisis Kinerja Energi Terbarukan Indonesia

Berdasarkan dashboard tersebut, wilayah Jawa memiliki kapasitas terpasang tertinggi, yaitu sekitar 1.284.556 MW, jauh melampaui wilayah lain seperti Sumatra dan Nusa Tenggara. Hal ini menunjukkan bahwa Jawa menjadi pusat utama pengembangan infrastruktur energi terbarukan di Indonesia. Temuan ini juga diperkuat oleh scatter plot yang menunjukkan Jawa memiliki produksi energi tertinggi dengan nilai sekitar 2.000K GWh, serta kapasitas terpasang yang juga paling besar, sehingga terlihat adanya hubungan positif antara kapasitas pembangkit dan realisasi produksi energi.

Dari sisi kontribusi jenis energi, energi Hydro memberikan kontribusi terbesar sebesar 22%, diikuti oleh Solar, Geothermal, dan Wind yang masing-masing berada di kisaran 18–20%. Hal ini mengindikasikan bahwa pembangkit hidro memiliki peran dominan dalam bauran energi terbarukan nasional, sementara kontribusi sumber energi lainnya relatif seimbang.


Pada bagian tren produksi energi bulanan, terlihat adanya fluktuasi produksi dari bulan ke bulan. Produksi sempat mencapai puncak sekitar 371.185 GWh, namun pada periode akhir mengalami penurunan signifikan hingga sekitar 136.775 GWh. Penurunan tajam ini dapat menjadi indikasi adanya faktor musiman, penurunan performa operasional, atau aktivitas maintenance pada beberapa fasilitas. Secara keseluruhan, dashboard ini menunjukkan bahwa wilayah dengan kapasitas besar cenderung menghasilkan produksi energi yang tinggi, namun



tren produksi yang fluktuatif perlu menjadi perhatian agar kestabilan pasokan energi tetap terjaga.

B. Dashboard Performa Operasional Dan Kinerja Energi Terbarukan

Berdasarkan visualisasi pada dashboard pada Gambar 38, ditampilkan “Analisis Performa Operasional Dan Kinerja Energi Terbarukan” yang mencakup perbandingan biaya operasional berdasarkan wilayah dan jenis energi, persentase status operasional fasilitas, persebaran populasi terlayani, serta perbandingan target tercapai berdasarkan tipe provider. Dashboard ini memberikan gambaran menyeluruh mengenai efisiensi operasional, cakupan layanan energi, serta tingkat keberhasilan provider dalam mencapai target yang telah ditetapkan.



Gambar 38 Dashboard Performa Operasional Dan Kinerja Energi Terbarukan

Berdasarkan dashboard tersebut, pada bagian biaya operasional, wilayah Jawa terlihat memiliki biaya tertinggi pada hampir seluruh jenis energi, terutama pada kategori Solar dan Unknown, dengan nilai yang mencapai lebih dari 70 miliar. Hal ini menunjukkan bahwa Jawa menjadi pusat aktivitas operasional energi terbesar, yang kemungkinan sejalan dengan skala proyek dan tingginya kebutuhan energi di wilayah tersebut.

Pada bagian status operasional, fasilitas energi didominasi oleh kondisi Active sebesar 40%, sementara Broken dan Maintenance masing-masing sebesar 30%. Insight ini menunjukkan



bahwa mayoritas fasilitas masih beroperasi dengan baik, namun proporsi fasilitas yang mengalami gangguan dan maintenance cukup besar sehingga perlu menjadi perhatian untuk menjaga stabilitas produksi energi.

Dari sisi persebaran populasi terlayani, wilayah Jawa kembali mendominasi dengan jumlah sekitar 6.764 juta jiwa, jauh lebih tinggi dibanding wilayah lain yang rata-rata berada pada kisaran 3 juta jiwa. Hal ini menunjukkan adanya ketimpangan distribusi layanan energi, di mana Jawa memiliki akses yang jauh lebih luas dibanding wilayah lainnya.

Pada bagian target tercapai berdasarkan tipe provider, provider Unknown memiliki jumlah populasi terlayani tertinggi baik pada kategori *No* maupun *Yes*, masing-masing sekitar 4.507 dan 4.505. Sementara provider lain seperti Government, Private, dan Foreign NGO memiliki nilai yang relatif seimbang antara target tercapai dan tidak tercapai. Hal ini mengindikasikan bahwa performa antar provider cukup stabil, namun dominasi kategori *Unknown* perlu dianalisis lebih lanjut karena kurangnya identitas provider dapat menyulitkan evaluasi kinerja dan penyusunan strategi perbaikan. Secara keseluruhan, dashboard ini menegaskan bahwa wilayah Jawa memiliki dominasi yang sangat kuat baik dari sisi biaya operasional, jumlah layanan, maupun performa energi.

3.3 Pembahasan

Berdasarkan hasil analisis secara menyeluruh, diperoleh beberapa insight strategis yang penting bagi Greindo dan pemangku kepentingan energi nasional.

Sebaran kapasitas energi di berbagai proyek masih belum merata. Sebagian besar fasilitas memiliki kapasitas kecil hingga menengah, sedangkan hanya sedikit yang berkapasitas besar dan biasanya terkonsentrasi di wilayah tertentu seperti Jawa. Kondisi ini menunjukkan adanya ketimpangan pembangunan infrastruktur energi antar daerah. Oleh karena itu, perlu adanya pemerataan pembangunan dan investasi, terutama di wilayah yang masih memiliki kapasitas rendah, agar distribusi energi menjadi lebih seimbang dan adil.

Produksi energi dari berbagai sumber terbarukan seperti Hydro, Solar, Wind, dan Geothermal sudah cukup seimbang. Hal ini menunjukkan bahwa pemanfaatan energi tidak bergantung pada satu jenis saja, sehingga lebih aman dan berkelanjutan. Namun, tetap diperlukan



pengembangan lebih lanjut, khususnya pada jenis energi yang memiliki potensi besar dan efisiensi tinggi, agar produksi energi bisa terus meningkat.

Produksi energi setiap bulan cenderung naik turun atau fluktuatif, namun secara umum masih berada pada kisaran yang stabil. Tidak terlihat pola musiman yang jelas, tetapi ada beberapa periode di mana produksi menurun cukup signifikan. Hal ini kemungkinan dipengaruhi oleh faktor operasional atau kondisi tertentu di lapangan. Oleh karena itu, perlu dilakukan pemantauan rutin dan analisis lebih lanjut untuk mengetahui penyebabnya, sehingga produksi dapat dijaga tetap stabil.

Secara umum, semakin besar kapasitas suatu fasilitas, semakin besar pula energi yang dihasilkan. Namun, terdapat beberapa kasus di mana fasilitas dengan kapasitas besar justru menghasilkan energi yang rendah. Hal ini menunjukkan adanya ketidakefisienan dalam operasional. Untuk mengatasinya, perlu dilakukan evaluasi dan pengecekan teknis agar fasilitas dapat bekerja secara optimal dan kapasitas yang tersedia bisa dimanfaatkan secara maksimal.

Saat ini, hanya sekitar 40% fasilitas yang benar-benar aktif, sementara sisanya masih dalam kondisi perawatan atau bahkan rusak. Hal ini menunjukkan bahwa masih banyak potensi energi yang belum dimanfaatkan secara maksimal. Oleh karena itu, perlu dilakukan peningkatan dalam pemeliharaan dan perbaikan fasilitas, serta penerapan sistem monitoring yang lebih baik agar lebih banyak fasilitas bisa kembali beroperasi.

Jika dilihat dari tipe provider (Pemerintah, Swasta, dan Asing), tingkat pencapaian target terlihat hampir sama. Namun, kondisi ini belum bisa dikatakan baik, karena jumlah proyek yang berhasil mencapai target masih seimbang dengan yang gagal. Artinya, tingkat keberhasilan secara keseluruhan masih perlu ditingkatkan. Untuk itu, perlu dilakukan evaluasi strategi kerja serta penerapan praktik terbaik dari provider yang memiliki kinerja lebih baik agar hasilnya bisa lebih maksimal.

Biaya operasional dalam menghasilkan energi berbeda-beda di setiap wilayah. Ada beberapa wilayah yang membutuhkan biaya tinggi tetapi hasil energinya tidak sebanding, yang menunjukkan adanya ketidakefisienan. Oleh karena itu, perlu dilakukan analisis lebih mendalam



terkait penggunaan biaya dan sumber daya, sehingga operasional bisa lebih efisien tanpa mengurangi jumlah energi yang dihasilkan.



BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan seluruh tahapan analisis, dataset Greindo pada awalnya memiliki berbagai permasalahan kualitas seperti nilai yang tidak konsisten, data hilang, duplikasi, dan outlier. Namun, melalui proses data preparation yang terstruktur, seluruh permasalahan tersebut berhasil ditangani sehingga data menjadi lebih bersih, konsisten, dan siap digunakan untuk analisis lebih lanjut. Dari sisi distribusi, kapasitas terpasang masih belum merata dan cenderung right-skewed, meskipun kontribusi antar jenis energi sudah cukup seimbang dan menunjukkan diversifikasi yang baik.

Di sisi lain, kondisi operasional fasilitas masih belum optimal karena hanya sekitar 40% yang aktif, sehingga masih banyak potensi produksi yang belum dimanfaatkan. Provider swasta juga terlihat memiliki kinerja lebih unggul dibandingkan provider lainnya. Selain itu, meskipun terdapat hubungan positif antara kapasitas dan produksi, masih ditemukan beberapa inefisiensi pada fasilitas tertentu. Hal ini menunjukkan perlunya peningkatan efisiensi operasional serta evaluasi lebih lanjut untuk memaksimalkan pemanfaatan kapasitas energi.

4.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, terdapat beberapa rekomendasi yang dapat diterapkan untuk meningkatkan kualitas data serta kinerja operasional energi terbarukan.

1. Diperlukan peningkatan program pemeliharaan preventif secara lebih intensif dan terjadwal. Mengingat hampir 60% fasilitas tidak berada dalam kondisi aktif, pemerintah dan pengelola perlu memprioritaskan perawatan rutin yang sistematis. Selain itu, alokasi anggaran untuk pemeliharaan perlu ditingkatkan, khususnya pada fasilitas dengan kapasitas besar yang mengalami kerusakan, agar potensi produksi yang hilang dapat segera dipulihkan.
2. Upaya pemerataan investasi energi terbarukan perlu terus didorong, terutama pada wilayah yang memiliki potensi sumber daya besar namun kapasitas terpasangnya masih rendah.



Kebijakan seperti pemberian insentif fiskal serta kemudahan dalam proses perizinan dapat menjadi strategi yang efektif untuk menarik minat investor ke wilayah-wilayah tersebut.

3. Kinerja provider swasta yang lebih unggul dapat dijadikan sebagai acuan. Pemerintah dapat memperluas kerja sama melalui skema Public-Private Partnership (PPP), serta mendorong pertukaran praktik terbaik antara sektor swasta dan pemerintah guna meningkatkan efisiensi operasional fasilitas secara keseluruhan.
4. Diperlukan standardisasi dalam sistem manajemen data energi. Greindo dapat berperan dalam mendorong penerapan standar pencatatan data yang seragam di seluruh fasilitas dan wilayah. Selain itu, penggunaan sistem input data yang tervalidasi secara otomatis dapat membantu meminimalkan kesalahan dan inkonsistensi data sejak awal.
5. Fasilitas yang menunjukkan ketidakseimbangan antara kapasitas dan produksi perlu dilakukan evaluasi lebih lanjut. Fasilitas dengan kapasitas besar namun produksi rendah sebaiknya diaudit secara teknis untuk mengetahui penyebab inefisiensi. Hasil evaluasi ini dapat digunakan sebagai dasar dalam pengambilan keputusan, baik untuk peningkatan teknologi, perbaikan operasional, maupun optimalisasi sumber daya.

Lampiran

A. Google Collab

https://colab.research.google.com/drive/1eFb0BaONNm4_CYpjVHDxV0S92obo9WaA?usp=sharing

B. Drive File Tableau

https://drive.google.com/file/d/1b0SX0fB1cr-lg_QAyrp68y1sole7-Lxm/view?usp=drive_link



C. Referensi

<https://chatgpt.com/c/69cfe98d-7acc-839f-822d-7a914a3d52f5>

<https://claude.ai/new>